

MANIFESTE

Le Data Scientist parfait

Doctrine, socle technique et grille d'évaluation
d'un métier qui vient de changer de nature

Sept axiomes · Huit piliers · Dix-huit anti-patterns · Grille de maturité 0-4

Table des matières

Avertissement de lecture	3
PRÉAMBULE	4
Pourquoi 2026 est une rupture, et pas une itération	4
PARTIE I — LE DIAGNOSTIC : CE QUI EST MORT	6
1. La fin du Data Scientist « notebook »	6
2. Ce que l'IA générative a commoditisé — et ce qu'elle n'a pas touché	7
3. Les trois métiers qui se cachaient sous un seul titre	9
PARTIE II — LA DOCTRINE : SEPT AXIOMES	11
4. Axiome I — La décision précède la donnée	11
5. Axiome II — La métrique métier est la seule fonction de perte qui compte	12
6. Axiome III — Le primat causal : corrélérer n'est pas décider	13
7. Axiome IV — Un modèle non déployé n'existe pas	15
8. Axiome V — L'incertitude est un livrable	16
9. Axiome VI — La simplicité est un choix d'ingénierie, jamais un aveu	17
10. Axiome VII — Locataire de son poste, propriétaire de ses compétences	18
PARTIE III — LE SOCLE TECHNIQUE : HUIT PILIERS	20
11. Pilier 1 — Statistique et probabilité : le socle non commoditisable	20
12. Pilier 2 — Inférence causale	21
13. Pilier 3 — Séries temporelles et prévision	22
14. Pilier 4 — Ingénierie logicielle : le vrai delta	24
15. Pilier 5 — Data engineering analytique et contrats de données	25
16. Pilier 6 — MLOps et plateforme	27
17. Pilier 7 — LLMOps, évaluation et systèmes agentiques	28
18. Pilier 8 — Économie de la décision	30
PARTIE IV — CE QUI SÉPARE LE BON DU DÉCISIF	32
19. Le cadrage : l'art de la question	32
20. La narration quantitative	33
21. La négociation du périmètre et l'art du refus	34
22. Éthique opérationnelle, conformité, gouvernance	35
PARTIE V — LES RÉGIMES DE PRATIQUE	38
23. Startup, scale-up, grand groupe, indépendant : quatre métiers différents	38
24. Rythme, artisanat et pratique délibérée	39
25. Les dix-huit anti-patterns	40
PARTIE VI — L'ÉVALUATION	42

26. Grille de maturité 0–4 par pilier	42
27. Le portfolio de preuves	43
28. Recruter : détecter le vrai en quatre-vingt-dix minutes	44
29. Plan 90 jours / 12 mois	45
ÉPILOGUE	47
Le Data Scientist parfait n'existe pas. Ce qu'il faut viser à la place.	47
ANNEXES	48
Annexe A — Table de traduction erreur → euros	48
Annexe B — Checklist de mise en production	48
Annexe C — Trente questions de cadrage	49
Annexe D — Lexique des faux amis	50

Avertissement de lecture

Ce texte n'est pas une fiche de poste, ni une liste de technologies à cocher. C'est une doctrine : un ensemble d'axiomes, de piliers, de refus et de critères d'évaluation. Il est écrit à charge — c'est-à-dire avec une thèse — et il assume de disqualifier une partie de ce qui se pratique aujourd'hui sous le nom de « data science ». Le mot « parfait » y est traité comme une asymptote opératoire, pas comme un état atteignable : la dernière section explique pourquoi la perfection est ici une direction de gradient, pas un point.

PRÉAMBULE

Pourquoi 2026 est une rupture, et pas une itération

Il y a un moment, dans la vie d'un métier, où l'accumulation d'outils cesse d'être une amélioration progressive et devient un changement de nature. Le métier de Data Scientist a connu ce moment entre 2023 et 2026.

Ce n'est pas parce que les modèles sont devenus plus gros. C'est parce que **la production de code analytique est devenue quasi gratuite**. Écrire une pipeline de features, un baseline gradient boosting, un notebook d'EDA, une API FastAPI, un dashboard Streamlit : ces tâches, qui constituaient encore en 2021 l'essentiel de la valeur observable d'un Data Scientist junior à confirmé, sont aujourd'hui réalisables en quelques minutes par un assistant de codage piloté par n'importe qui sachant formuler une intention.

La conséquence est brutale et mal digérée par la profession : **la production n'est plus le goulot d'étranglement. Le jugement l'est.**

Un métier dont la valeur reposait sur la capacité à produire un artefact technique voit cette valeur s'effondrer quand l'artefact devient gratuit. Un métier dont la valeur repose sur la capacité à décider *quel* artefact produire, à *quelle question* il répond, *quelle décision* il modifie et *combien vaut* cette modification, voit sa valeur augmenter dans le même mouvement.

Ce manifeste part de là. Il décrit ce que devient le métier quand on retire de l'équation tout ce que la machine sait faire seule.

Les quatre déplacements

Déplacement 1 : du modèle à la décision. Un modèle n'a pas de valeur. Une décision modifiée a une valeur. Le Data Scientist de 2026 raisonne en delta décisionnel : quelle décision serait prise sans mon travail, quelle décision est prise avec, quelle est la différence en euros ou en risque évité. Tout le reste est de l'artisanat instrumental.

Déplacement 2 : de la prédiction à l'intervention. Prédire est devenu bon marché. Répondre à « que se passe-t-il si j'agis » reste cher, parce que cela demande un raisonnement contrefactuel que les données observationnelles ne donnent jamais gratuitement. L'inférence causale n'est plus une spécialité exotique : c'est la compétence de séparation la plus nette du marché.

Déplacement 3 : de la précision à la fiabilité. Le monde ne manque pas de modèles précis un mardi de mars sur un jeu de test. Il manque de systèmes qui restent honnêtes dix-huit mois, sous dérive, sous incident amont, sous changement de définition métier, sous rotation d'équipe. La fiabilité est une compétence d'ingénierie et de gouvernance, pas de modélisation.

Déplacement 4 : de l'exécution au cadrage. Quand l'exécution est gratuite, le coût de la mauvaise question explose en proportion. Un système parfaitement exécuté qui répond à

la mauvaise question est plus coûteux en 2026 qu'en 2019, parce qu'il est produit plus vite, déployé plus vite, et adopté plus vite avant que l'erreur ne soit détectée.

Ce que ce manifeste refuse

Il refuse la définition par les outils. « Maîtrise Python, SQL, Spark, PyTorch » ne décrit pas un professionnel, cela décrit un environnement de travail. Personne ne définit un chirurgien par sa maîtrise du bistouri.

Il refuse la définition par le titre. « Data Scientist », « ML Engineer », « Analytics Engineer », « AI Engineer » : ces frontières sont des artefacts d'organigramme, redécoupés tous les dix-huit mois par des directions qui ne savent pas nommer ce qu'elles achètent. Le professionnel se définit par les problèmes qu'il sait clore, pas par la case dans laquelle on l'a rangé.

Il refuse la définition par la nouveauté. Un métier qui se redéfinit à chaque sortie de modèle n'est pas un métier, c'est une mode. Ce qui suit distingue soigneusement ce qui a changé (beaucoup) de ce qui n'a pas bougé depuis quarante ans (l'essentiel du socle).

PARTIE I — LE DIAGNOSTIC : CE QUI EST MORT

1. La fin du Data Scientist « notebook »

1.1. Portrait d'un archétype en fin de vie

L'archétype dominant de 2015–2022 était le suivant : une personne formée à la statistique ou au machine learning, travaillant principalement dans Jupyter, dont le livrable canonique était un notebook contenant une exploration, une modélisation, des courbes ROC et une conclusion en cellule Markdown. Le passage en production, quand il avait lieu, était délégué à « l'IT ». Le taux de mise en production réel des travaux produits par cet archétype se situait, selon les organisations, entre 10 % et 30 %.

Cet archétype est mort de trois causes simultanées.

Cause 1 : la commoditisation de sa production. Le notebook exploratoire type — chargement, profiling, corrélations, quelques modèles comparés, feature importance — est aujourd'hui généré en quelques minutes par un assistant. Sa valeur marginale a rejoint son coût marginal : zéro.

Cause 2 : l'exigence de bout-en-bout. Les organisations ont fini par apprendre, souvent chèrement, que la valeur ne se matérialise qu'après le déploiement. Le rôle qui s'arrête au notebook est structurellement incapable de produire de la valeur ; il produit de la matière première pour un autre rôle, avec un coût de coordination souvent supérieur au bénéfice.

Cause 3 : l'écart de qualité invisible. Le notebook masque tout : fuite de données temporelle, split aléatoire sur série temporelle, réajustement du seuil sur le jeu de test, encodage de cible sans validation croisée imbriquée, métrique choisie après avoir vu les résultats. Ces erreurs ne sont pas détectables par un manager non technique. Elles ne se paient qu'en production, six mois plus tard, quand le modèle sous-performe la règle métier qu'il a remplacée.

1.2. Ce qui remplace le notebook

Le notebook n'est pas condamné comme outil. Il est condamné **comme livrable**. Le livrable de 2026 est un des quatre objets suivants, jamais autre chose :

Livrable	Ce qu'il contient	Comment on vérifie qu'il existe
Un système en production	Code versionné, tests, CI/CD, monitoring, runbook, propriétaire nommé	Il tourne sans son auteur pendant trois semaines
Une décision documentée	Question, méthode, résultat, incertitude, recommandation, ce qui invaliderait la conclusion	Le décideur a changé d'avis ou a confirmé son choix avec un argument nouveau

Livrable	Ce qu'il contient	Comment on vérifie qu'il existe
Un actif réutilisable	Dataset certifié, feature store, package interne, template, framework d'évaluation	Une autre équipe l'utilise sans demander d'aide
Un refus argumenté	Pourquoi la question ne peut pas être traitée, ce qui manque, quelle alternative	L'organisation a économisé un projet

Le notebook devient ce qu'il aurait toujours dû être : **un brouillon de laboratoire**. Utile, jetable, jamais montré comme preuve de travail achevé.

1.3. Le test du tiroir

Un test simple pour évaluer l'archétype d'un professionnel : demander ce qui se passe si on ferme son ordinateur pendant un mois.

- Si tout s'arrête : il *est* le système. Il n'a rien construit, il opère.
- Si tout continue mais rien ne progresse : il a construit un système, il n'a pas construit d'équipe.
- Si tout continue et que quelqu'un d'autre a amélioré son travail sans lui demander : il a construit un actif.

Le professionnel de 2026 vise le troisième cas. C'est le seul qui compose dans le temps.

2. Ce que l'IA générative a commodité — et ce qu'elle n'a pas touché

2.1. La zone rouge : ce qui ne vaut plus rien

Il faut nommer précisément ce qui s'est effondré, sans complaisance et sans catastrophisme.

Effondré totalement :

- La syntaxe. Connaître par cœur l'API de pandas, l'ordre des arguments de `train_test_split`, la façon d'écrire une fenêtre glissante en SQL. Cette connaissance a une valeur strictement nulle en 2026.
- Le code de plomberie. Parsers, connecteurs, transformations de format, scripts d'export, wrappers d'API, boilerplate de tests.
- Le baseline. Un LightGBM correctement paramétré sur un tableau propre, un ARIMA sur une série, une régression logistique avec encodage : la machine produit cela mieux et plus vite que la médiane des humains.
- La documentation descriptive. Docstrings, README de structure, commentaires de code, résumés de notebook.
- L'exploration de première passe. Distributions, valeurs manquantes, cardinalités, corrélations, premières visualisations.
- La veille de surface. Résumer un papier, comparer trois bibliothèques, expliquer une architecture connue.

Cette liste représente, dans beaucoup d'organisations, entre 50 % et 70 % du temps réellement passé par les équipes data en 2021. C'est l'ampleur du choc. Un professionnel dont le portefeuille de compétences se situait majoritairement dans cette liste a vu sa valeur de marché divisée, pas réduite à la marge.

2.2. La zone verte : ce qui a pris de la valeur

Symétriquement, certaines compétences ont vu leur valeur relative augmenter, précisément parce que le reste s'est effondré.

Le cadrage. Traduire un problème métier flou en une question statistiquement traitable, avec une unité d'analyse, une population, une fenêtre temporelle, une métrique de succès et un critère d'arrêt. Aucun assistant ne fait cela, parce que cela demande de savoir ce que l'organisation ne dit pas.

Le jugement sur la validité. Savoir qu'un résultat est faux avant de savoir pourquoi. Cette intuition — l'odeur du surapprentissage, la sensation qu'un R^2 de 0,97 sur des données réelles est un aveu de fuite, la méfiance devant un uplift de 40 % — est une compétence bayésienne construite par l'expérience répétée de l'échec. Elle ne s'externalise pas.

La conception d'expériences et l'identification causale. Choisir entre A/B test, DiD, synthetic control, RDD, instrument, DAG explicite ; savoir quelles hypothèses chacun exige et lesquelles sont réfutables dans le contexte donné. C'est un travail d'argumentation scientifique sur des hypothèses non testables, pas un travail de calcul.

L'architecture des systèmes de décision. Où placer le modèle dans le processus, qui décide en cas de désaccord, quel est le comportement en mode dégradé, quel est le seuil de bascule vers l'humain, comment on éteint le système. Ce sont des choix socio-techniques.

L'évaluation. Construire un dispositif d'évaluation crédible pour un système dont la sortie est non déterministe et non structurée est devenu le travail le plus difficile et le plus recherché du domaine. Voir Pilier 7.

La responsabilité. Signer. Dire « je réponds de ce chiffre ». Aucun modèle ne peut porter cela, pour des raisons qui ne sont pas techniques mais juridiques et sociales.

2.3. Le piège du milieu

Entre la zone rouge et la zone verte se trouve un espace dangereux : les compétences qui *semblent* commoditisées mais dont la commoditisation est une illusion. Ce sont les plus coûteuses à mal évaluer.

Exemple 1 — Le feature engineering. Un assistant génère cent features en trente secondes. Il ne sait pas que la variable `date_saisie_dossier` est renseignée *après* l'événement à prédire dans 8 % des cas, à cause d'un correctif manuel effectué par le service client. Cette connaissance-là est la seule qui compte, et elle est locale, non écrite, sociale.

Exemple 2 — Le choix de modèle. L'assistant propose un ensemble de gradient boosting. Il ne sait pas que le comité de crédit exige une monotonie stricte sur trois variables pour des raisons réglementaires, ni que le refus de crédit doit être explicable en une phrase à un client.

Exemple 3 — Le nettoyage. Automatisable en apparence. Mais décider si une valeur aberrante est une erreur de saisie, un événement réel rare, ou un signal précurseur est une décision de modélisation déguisée en tâche de nettoyage. Elle a des conséquences en aval qu'aucune heuristique ne capture.

Règle générale : ce qui est commoditisé, c'est la manipulation des symboles. Ce qui ne l'est pas, c'est le raccordement des symboles au monde. Le Data Scientist de 2026 est un professionnel du raccordement.

2.4. Le nouveau rapport à l'outil

Le professionnel de 2026 utilise massivement les assistants — refuser de le faire est une faute de productivité, pas une preuve de rigueur. Mais il les utilise selon un protocole strict :

1. **Il ne délègue jamais la définition du problème.** L'assistant reçoit une spécification, il ne la produit pas.
2. **Il ne délègue jamais la validation.** Tout code généré est relu et testé ; tout résultat produit est vérifié par un chemin indépendant (ordre de grandeur, contrôle sur sous-population, comparaison à une source externe).
3. **Il délègue la production, jamais la compréhension.** Un professionnel qui ne peut pas expliquer ligne à ligne le code qu'il a mis en production a signé un chèque sans lire le montant.
4. **Il traite l'assistant comme un stagiaire brillant, rapide, sûr de lui et parfois complètement à côté.** Cette métaphore est opératoire : elle dicte le niveau de supervision.
5. **Il mesure.** Le gain de productivité doit être constaté, pas supposé. Beaucoup d'équipes ont mesuré un gain net négatif sur les tâches complexes, à cause du coût de relecture du code généré.

3. Les trois métiers qui se cachaient sous un seul titre

Le titre « Data Scientist » a longtemps recouvert trois professions distinctes, avec des socles, des rythmes et des critères de qualité incompatibles. La confusion a produit des recrutements ratés en série et des carrières bloquées. Il faut les séparer explicitement, parce que **la perfection ne se définit pas de la même manière dans les trois cas.**

3.1. Le Scientifique de la décision (Decision Scientist)

Question type : « Faut-il ouvrir ce point de vente ? », « Notre promotion a-t-elle créé de la valeur ou déplacé des ventes ? », « Quel est l'effet du délai de livraison sur la rétention ? »

Livrable : une décision documentée, une quantification d'effet avec intervalle de confiance, une recommandation assortie de ses conditions d'invalidation.

Socle dominant : statistique inférentielle, inférence causale, design expérimental, économétrie, communication.

Rythme : études de deux à huit semaines. Peu ou pas de code en production.

Critère de qualité : la décision a été modifiée, et rétrospectivement elle était bonne. La justesse du raisonnement compte plus que la performance prédictive.

Erreur classique : être évalué sur des KPI de production (nombre de modèles déployés) alors que son métier est de produire du jugement.

3.2. L'Ingénieur en apprentissage automatique (ML Engineer)

Question type : « Comment servir cinq mille prédictions par seconde avec une latence p99 sous 80 ms et un réentraînement hebdomadaire auditable ? »

Livrable : un système en production, monitoré, testé, documenté, avec un runbook et un propriétaire.

Socle dominant : ingénierie logicielle, systèmes distribués, MLOps, observabilité, coût d'infrastructure.

Rythme : trimestres. Cycles de dette technique.

Critère de qualité : disponibilité, latence, coût par prédiction, temps moyen de restauration, absence de dérive silencieuse.

Erreur classique : être recruté sur des tests d'algorithmique statistique alors que son métier est l'ingénierie de fiabilité.

3.3. L'Ingénieur en systèmes d'IA (AI / Agentic Engineer)

Profil apparu en 2023, stabilisé en 2025–2026.

Question type : « Comment construire un système qui traite quatre-vingts pour cent des demandes de niveau 1 avec un taux d'erreur inférieur à deux pour cent, un coût unitaire sous quatre centimes, et une trace auditable de chaque décision ? »

Livrable : un système composite — orchestration, outils, mémoire, garde-fous, évaluation continue, boucle de rattrapage humaine.

Socle dominant : conception de systèmes non déterministes, évaluation, ingénierie du contexte, arbitrage coût/latence/qualité, sécurité applicative (injection de prompt, exfiltration, permissions).

Rythme : itérations courtes, mais avec une dette d'évaluation qui se paie très vite.

Critère de qualité : taux de réussite de bout en bout sur un jeu d'évaluation représentatif, coût unitaire, taux d'escalade, absence de régression entre versions de modèle fournisseur.

Erreur classique : confondre démonstration et système. Un prototype qui marche sur dix cas et un système qui tient sur dix mille sont séparés par deux ordres de grandeur d'effort, dont la quasi-totalité est de l'évaluation.

3.4. Le profil complet : ce que « parfait » signifie

Le Data Scientist parfait n'est **pas** celui qui fait les trois métiers au même niveau. Cette figure n'existe pas et sa poursuite produit des professionnels médiocres partout.

La configuration réaliste, et celle que ce manifeste défend, est la suivante :

Une profondeur d'expert sur l'un des trois axes, une compétence opérationnelle réelle sur le deuxième, une littératie suffisante sur le troisième pour ne jamais être trompé.

C'est la structure en « T asymétrique », ou plus justement en « **Π** » (**pi**) : deux jambes solides, une barre transversale large. Un professionnel avec une seule jambe est fragile. Un professionnel avec une barre sans jambe est un généraliste sans pouvoir de clôture — le profil le plus menacé de 2026, parce que la barre transversale est précisément ce que les assistants fournissent gratuitement.

La barre transversale ne vaut plus rien seule. **La profondeur, elle, est devenue la seule rente.**

PARTIE II — LA DOCTRINE : SEPT AXIOMES

Un axiome n'est pas une bonne pratique. Une bonne pratique se négocie selon le contexte ; un axiome, non. Les sept qui suivent sont des invariants : un professionnel qui en viole un régulièrement n'est pas « pragmatique », il produit un travail dont la valeur est indéterminée.

4. Axiome I — La décision précède la donnée

4.1. Énoncé

Aucun travail ne commence avant qu'on ait nommé la décision qu'il modifie, la personne qui la prend, la fréquence à laquelle elle est prise, et ce qui serait fait en l'absence de tout modèle.

4.2. Justification

La totalité des projets data échoués que l'on peut auditer partagent une caractéristique : personne ne pouvait répondre à la question « qui fait quoi différemment quand ce système existe ? ». Non pas parce que la réponse était mauvaise, mais parce que la question n'avait jamais été posée.

Le mécanisme d'échec est mécanique. En l'absence de décision cible : - La métrique de succès est choisie par défaut (AUC, RMSE), c'est-à-dire par le modélisateur, c'est-à-dire par la personne qui a le moins d'information sur la valeur. - Le périmètre dérive, parce qu'aucun critère ne permet de dire non. - La livraison n'a pas de destinataire, donc pas d'adoption. - L'évaluation post-déploiement est impossible, parce qu'il n'y a pas de contrefactuel organisationnel.

4.3. Le protocole des cinq questions

Aucun projet ne démarre sans réponses écrites à ces cinq questions. Écrites, pas orales : l'oral autorise l'ambiguïté.

1. **Quelle décision ?** Formulée comme un verbe d'action avec un sujet et un objet. « Décider quels clients contacter cette semaine », pas « mieux comprendre le churn ».
2. **Par qui ?** Un nom, pas un service.
3. **À quelle fréquence, avec quel délai acceptable ?** Une décision hebdomadaire tolère un batch nocturne. Une décision au point de vente exige 200 ms.
4. **Que fait-on aujourd'hui sans modèle ?** C'est le baseline réel. Le baseline n'est jamais « rien » : c'est une règle, une habitude, un expert, un tableur. Ce baseline doit être mesuré avant toute modélisation. Un modèle qui ne bat pas la règle métier existante n'a aucune valeur, quelle que soit son AUC.
5. **Combien vaut une amélioration d'un point ?** Si personne ne sait, le projet n'a pas de sponsor réel, seulement un demandeur.

4.4. Le cas des projets exploratoires

Objection fréquente : « certaines études sont exploratoires, on ne sait pas encore quelle décision ». C'est recevable, à une condition : **l'exploration doit être bornée par une décision méta**. « À l'issue de ces trois semaines, nous déciderons d'investir ou d'abandonner ce sujet, selon le critère suivant : ... ». L'exploration sans critère d'arrêt n'est pas de la recherche, c'est de l'occupation.

4.5. Refus associé

Refus n° 1 : je ne démarre pas un projet dont la décision cible n'est pas nommée. Si le commanditaire ne peut pas la nommer, mon premier livrable est un atelier de cadrage, pas un modèle.

5. Axiome II — La métrique métier est la seule fonction de perte qui compte

5.1. Énoncé

Toute métrique statistique doit être reliée par une chaîne explicite et chiffrée à une grandeur métier. Une métrique sans chaîne de traduction est un indicateur de confort.

5.2. Le problème de l'asymétrie

Les fonctions de perte standard sont symétriques ou arbitrairement pondérées. Le monde ne l'est jamais.

- En prévision de la demande : sous-estimer coûte une rupture (marge perdue + insatisfaction + report concurrent) ; surestimer coûte du stock (immobilisation + démarque + destruction si périssable). Le rapport de coût est typiquement compris entre 1:3 et 8:1 selon le produit. Optimiser un RMSE symétrique dans ce contexte est une faute méthodologique, pas une approximation.
- En détection de fraude : un faux négatif coûte le montant de la fraude ; un faux positif coûte un client bloqué et un appel au service client. Le rapport dépend du montant, donc la métrique doit être pondérée par la valeur de la transaction.
- En maintenance prédictive : un faux négatif coûte un arrêt de ligne ; un faux positif coûte une intervention. Rapport typique de 1:20 à 1:200.

Conséquence pratique : le professionnel de 2026 construit, pour chaque projet, une **matrice de coût explicite** validée par le métier, et optimise contre elle. Cela peut prendre la forme d'une perte quantile (pinball loss) asymétrique, d'un seuil de décision optimisé sur une courbe de coût, ou d'une fonction de perte personnalisée.

5.3. La table de traduction

Chaque projet dispose d'un tableau tenu à jour du type suivant (exemple, prévision de demande sur produit frais) :

Grandeur statistique	Traduction opérationnelle	Traduction financière
−1 point de WMAPE hebdomadaire	−0,6 jour de couverture moyenne	≈ 240 k€ de BFR libéré / an
−1 point de sous-prévision sur top 50 réf.	−0,3 pt de taux de rupture	≈ 180 k€ de marge non perdue / an
+1 point de sur-prévision produit frais	+0,4 pt de démarque	≈ −95 k€ / an

Grandeur statistique	Traduction opérationnelle	Traduction financière
Prévision livrée D+1 au lieu de D+3	2 jours de réactivité appro	non chiffré, effet qualitatif

Ce tableau n'a pas besoin d'être exact. Il a besoin d'être **explicite, partagé et contesté**. Sa fonction première n'est pas la précision comptable : c'est de forcer le métier à révéler sa structure de coûts, ce qui change presque toujours la conception du modèle.

5.4. Le test de l'indicateur mort

Un indicateur est mort si personne ne peut décrire une action qu'il déclenche. Les indicateurs morts consomment du temps de calcul, du temps de réunion et de l'attention. Le professionnel les supprime activement — supprimer un indicateur est un livrable légitime.

5.5. Refus associé

Refus n° 2 : je ne livre pas de métrique de performance sans sa traduction métier. Si la traduction est impossible à établir, je le dis explicitement dans le livrable plutôt que de laisser croire à une valeur non démontrée.

6. Axiome III — Le primat causal : corrélér n'est pas décider

6.1. Énoncé

Dès qu'une décision consiste à *agir sur* une variable, la modélisation prédictive observationnelle est invalide comme support de décision. Il faut une identification causale explicite.

6.2. Pourquoi c'est le sujet central de 2026

La prédiction est commoditisée ; l'action ne l'est pas. Or la quasi-totalité des demandes métier à forte valeur sont des demandes d'action déguisées en demandes de prédiction :

- « Prédire le churn » → en réalité : « qui dois-je contacter, et le contact réduit-il le churn ? »
- « Prédire les ventes selon le prix » → en réalité : « quel prix dois-je fixer ? »
- « Prédire quels clients répondront à la promo » → en réalité : « à qui envoyer la promo pour maximiser l'incrémental ? »

Dans les trois cas, un modèle prédictif entraîné sur l'historique répond à la mauvaise question et peut produire une décision **anti-optimale**. Le cas canonique du ciblage promotionnel : le modèle prédictif cible les clients à forte probabilité d'achat, qui sont précisément ceux qui auraient acheté sans promotion. On subventionne les achats certains. L'uplift modeling existe exactement pour éviter cela, et reste sous-utilisé.

Le cas canonique du prix : dans les données historiques, les prix élevés sont souvent corrélés à des ventes élevées, parce que les prix montent quand la demande est forte. Un modèle prédictif naïf apprend une élasticité de signe positif et recommande d'augmenter les prix indéfiniment. Ce n'est pas une erreur exotique de manuel : c'est l'erreur la plus fréquemment observée en pricing.

6.3. La hiérarchie des preuves

Le professionnel connaît et sait choisir dans cette hiérarchie, par ordre décroissant de crédibilité :

1. **Expérimentation randomisée** (A/B, switchback, geo-experiment, cluster-randomized). L'étalon-or. Coût : temps, risque commercial, faisabilité organisationnelle.
2. **Expérience naturelle avec assignation quasi-aléatoire** — discontinuité de régression (RDD), variable instrumentale crédible.
3. **Différence-de-différences** et ses extensions modernes (estimateurs robustes à l'hétérogénéité temporelle des effets de traitement, adoption échelonnée).
4. **Contrôle synthétique** (et ses versions bayésiennes type CausalImpact) pour les interventions uniques sur unité agrégée.
5. **Ajustement observationnel sous hypothèse d'ignorabilité conditionnelle** — appariement, pondération par le score de propension, double machine learning, forêts causales.
6. **Modèle structurel / DAG avec hypothèses assumées.**
7. **Corrélation commentée.** Ce n'est pas une preuve causale ; ne jamais la présenter comme telle.

Point de doctrine : un professionnel qui ne sait produire que le niveau 7 et le vend au niveau 1 commet une faute déontologique, pas une approximation technique.

6.4. L'obligation du DAG

Avant toute estimation d'effet, le professionnel dessine le graphe causal supposé et le fait **contester** par le métier. Ce dessin sert à trois choses :

- Identifier les **confondants** à ajuster.
- Identifier les **colliders** à ne surtout pas ajuster (conditionner sur un collider crée un biais là où il n'y en avait pas — erreur silencieuse et fréquente).
- Identifier les **médiateurs**, dont l'ajustement détruit précisément l'effet qu'on cherche à mesurer.

Le DAG est un objet de discussion métier, pas un artefact académique. Il révèle systématiquement des mécanismes que personne n'avait explicités.

6.5. Les tests de réfutation

Toute estimation causale est accompagnée de tests de robustesse, non optionnels : - Traitement placebo (appliqué à une période où rien ne s'est passé). - Outcome placebo (une variable qui ne devrait pas être affectée). - Ajout d'un confondant aléatoire. - Retrait d'un sous-échantillon. - Analyse de sensibilité à un confondant non observé (jusqu'à quelle force de confusion la conclusion tient-elle ?).

Une estimation causale sans tests de réfutation est une opinion chiffrée.

6.6. Refus associé

Refus n° 3 : je ne recommande pas d'action sur la base d'un modèle purement prédictif observationnel. Soit j'obtiens un design d'identification, soit je livre l'analyse avec un avertissement explicite de non-causalité en tête de document, pas en note de bas de page.

7. Axiome IV — Un modèle non déployé n'existe pas

7.1. Énoncé

La valeur d'un modèle est strictement nulle jusqu'à son intégration dans un processus de décision réel. Un modèle à 0,94 d'AUC non déployé vaut moins qu'une règle métier à 0,71 utilisée quotidiennement.

7.2. Le vrai coût de la chaîne

La répartition d'effort réelle sur un système de ML en production, mesurée sur des projets menés à terme :

Phase	Part de l'effort total	Perception courante
Cadrage, accès données, compréhension métier	25-35 %	« préliminaires »
Préparation, qualité, contrats de données	20-30 %	« nettoyage »
Modélisation proprement dite	5-15 %	« le projet »
Industrialisation, tests, CI/CD, monitoring	20-30 %	« la mise en prod »
Adoption, formation, conduite du changement	10-20 %	« pas mon travail »

La modélisation, cœur perçu du métier, représente une fraction minoritaire de l'effort. Un professionnel qui ne s'intéresse qu'à cette fraction s'intéresse à un dixième de son métier.

7.3. La définition de « déployé »

Un système est déployé quand les huit conditions suivantes sont vraies. Sept sur huit signifie non déployé.

1. Il tourne sur une infrastructure qui n'est pas le poste de son auteur.
2. Il est déclenché automatiquement, sans intervention manuelle.
3. Ses entrées sont contractualisées (schéma, fraîcheur, volumétrie attendue) et vérifiées à l'exécution.
4. Ses sorties sont consommées par un processus identifié.
5. Ses échecs alertent quelqu'un, avec une procédure de reprise écrite.
6. Sa performance est mesurée en continu contre le réel, pas contre un jeu de test figé.
7. Il peut être réentraîné et redéployé de façon reproductible par une autre personne.
8. Il peut être **éteint** proprement, et le mode dégradé est spécifié.

Le point 8 est le plus souvent omis et le plus coûteux. Tout système doit avoir un plan de mort.

7.4. Le principe de la première ligne

Corollaire opératoire : **le premier livrable d'un projet est une chaîne de bout en bout la plus stupide possible, en production.** Une moyenne mobile, une règle métier, une constante. Elle est déployée, monitorée, consommée.

Cette pratique — le « walking skeleton » — a trois vertus : - Elle révèle immédiatement les vrais obstacles (accès, droits, latence, format, intégration), qui sont toujours ailleurs que là où on les attendait. - Elle établit le baseline réel contre lequel tout gain sera mesuré. - Elle produit de la valeur tôt, ce qui protège le projet politiquement.

L'ordre inverse — modéliser six mois puis chercher à déployer — est la cause la plus fréquente d'abandon de projet.

7.5. Refus associé

Refus n° 4 : je n'accepte pas de mission dont le périmètre s'arrête avant le déploiement, sauf si le commanditaire assume explicitement par écrit que le livrable est une étude et non un système, avec le nom de l'équipe qui prendra la suite.

8. Axiome V — L'incertitude est un livrable

8.1. Énoncé

Une prédiction ponctuelle sans quantification d'incertitude est une information incomplète et souvent dangereuse. L'incertitude n'est pas une réserve de prudence : c'est une donnée d'entrée pour la décision.

8.2. Pourquoi c'est structurel, pas cosmétique

En prévision de la demande, la décision de stock ne se prend pas sur la prévision médiane mais sur un quantile élevé, dont le niveau est déterminé par le ratio coût de rupture / coût de possession. Le modèle *newsvendor* le dit depuis 1888 : **la bonne décision est un quantile, pas une moyenne**. Livrer une prévision ponctuelle à un planificateur, c'est le forcer à reconstruire mentalement une incertitude qu'on avait dans le modèle et qu'on a jetée.

Même logique ailleurs : - Un score de risque sans calibration ne permet pas de fixer un seuil rationnel. - Une estimation d'effet causal sans intervalle ne permet pas de décider si l'investissement est justifié. - Une prédiction de maintenance sans probabilité ne permet pas d'ordonnancer les interventions.

8.3. Les trois incertitudes à distinguer

Le professionnel distingue et nomme :

1. **L'incertitude aléatoire** (bruit irréductible du processus). Ne diminue pas avec plus de données. Détermine la borne de performance atteignable — que l'on doit estimer avant de promettre quoi que ce soit.
2. **L'incertitude épistémique** (méconnaissance du modèle). Diminue avec plus de données ou un meilleur modèle. Détermine s'il est rentable d'investir davantage.
3. **L'incertitude de spécification** (le modèle est peut-être faux). Ne se quantifie pas dans le modèle ; se traite par comparaison de familles de modèles, par backtesting sur régimes différents, et par honnêteté.

Confondre la première et la deuxième conduit à promettre des améliorations impossibles. Ignorer la troisième conduit aux ruines les plus spectaculaires.

8.4. Les outils

- **Intervalles de prédiction calibrés**, pas des intervalles de confiance sur la moyenne — la confusion est courante et grave.
- **Prédiction conforme** (conformal prediction) : garantie de couverture distribution-free, applicable à n'importe quel modèle, y compris en régime non-échangeable avec les variantes adaptatives. C'est aujourd'hui l'outil par défaut pour un praticien pressé et rigoureux.

- **Quantile regression** / pinball loss quand la décision est directement un quantile.
- **Approches bayésiennes** quand la structure du problème l'exige (petits échantillons, hiérarchies, connaissance a priori forte).
- **Backtesting sur fenêtre glissante** avec origine roulante : la seule évaluation honnête en contexte temporel.

8.5. La règle de calibration

Un modèle probabiliste doit être **calibré** avant d'être **précis**. Un modèle mal calibré mais discriminant est utilisable pour classer, jamais pour décider d'un seuil ou pour calculer une espérance. Le diagramme de fiabilité doit figurer dans tout livrable produisant des probabilités.

8.6. Refus associé

Refus n° 5 : je ne livre pas de prévision ponctuelle nue quand la décision aval est asymétrique. Si l'outil consommateur ne sait afficher qu'un nombre, je livre le quantile approprié à la décision, et je documente lequel.

9. Axiome VI — La simplicité est un choix d'ingénierie, jamais un aveu

9.1. Énoncé

Le modèle retenu est le plus simple qui atteint le seuil de performance utile. La complexité doit être justifiée par un gain mesuré et supérieur à son coût total de possession.

9.2. Le coût réel de la complexité

Un modèle complexe coûte, au-delà de son entraînement : - Du temps de compréhension pour chaque nouvel arrivant (amorti sur trois ans, c'est le poste le plus lourd). - De la surface d'échec (plus de dépendances, plus de points de rupture). - De la difficulté d'audit et d'explication, avec un coût réglementaire croissant. - De la latence et du coût d'inférence. - De la fragilité au changement de distribution : les modèles à forte capacité mémorisent mieux les régularités du passé, y compris celles qui ne survivront pas.

Ce coût est payé chaque mois. Le gain de performance, lui, est mesuré une fois, souvent optimistiquement.

9.3. Le protocole d'escalade

L'ordre de montée en complexité est fixé, et chaque étage doit battre le précédent d'une marge définie à l'avance, en évaluation temporellement honnête :

Étage	Exemple (prévision)	Exemple (classification)
0	Constante, dernière valeur	Classe majoritaire
1	Naïve saisonnière, moyenne mobile	Règle métier existante
2	Lissage exponentiel, ARIMA, Theta	Régression logistique régularisée
3	Gradient boosting sur features calendaires + retards	Gradient boosting
4	Modèles globaux multi-séries, hiérarchie réconciliée	Ensembles, calibration
5	Réseaux profonds temporels (N-BEATS, TFT, DeepAR)	Réseaux profonds, embeddings

Étage	Exemple (prévision)	Exemple (classification)
6	Modèles de fondation temporels, ensembles hybrides	Architectures spécialisées

Règle de marge : un étage supplémentaire n'est retenu que s'il apporte un gain supérieur à 2 % relatif *et* statistiquement distinguable sur backtest à origines multiples, *et* qu'il ne dégrade pas les critères d'exploitabilité. Sur données tabulaires et sur la majorité des séries d'entreprise, les étages 2 et 3 restent la zone de rendement optimal — un fait empirique constant et régulièrement redécouvert.

9.4. La règle du « plus grand modèle qui échoue »

Pratique diagnostique utile : entraîner délibérément un modèle très flexible pour établir la borne supérieure atteignable sur les données disponibles. Si l'écart avec l'étage 2 est faible, le problème est **limité par le signal, pas par le modèle**. La conclusion est alors qu'il faut chercher des données, pas des architectures. Cette information vaut plus que trois semaines d'optimisation d'hyperparamètres.

9.5. Refus associé

Refus n° 6 : je ne déploie pas un modèle plus complexe que nécessaire pour des raisons de prestige technique, de curiosité personnelle ou de demande de « faire de l'IA ». Si la demande porte sur la technologie plutôt que sur le résultat, je la requalifie ou je la décline.

10. Axiome VII — Locataire de son poste, propriétaire de ses compétences

10.1. Énoncé

Le poste est un contexte temporaire ; la compétence est un actif personnel qui se déprécie sans entretien. L'entretien est une obligation professionnelle, pas un loisir.

10.2. La demi-vie des compétences

Toutes les compétences ne se déprécient pas au même rythme. Un professionnel lucide connaît son portefeuille et sa structure de dépréciation :

Nature	Demi-vie approximative	Exemples
Syntaxe et API	12-24 mois	signatures de bibliothèques, options de services cloud
Outils	3-5 ans	orchestrateurs, formats, plateformes
Architecture et patterns	7-12 ans	conception de systèmes, séparation des responsabilités
Méthodes statistiques et causales	20-40 ans	inférence, design expérimental, théorie de la décision
Jugement, cadrage, communication	croissant avec l'âge	négociation de périmètre, lecture d'organisation

Conséquence stratégique : investir principalement dans la première ligne est une stratégie de dépréciation garantie. Le professionnel de 2026 investit majoritairement dans les trois dernières,

et maintient la première au strict niveau opérationnel — d'autant plus que les assistants couvrent désormais l'essentiel de la ligne 1.

10.3. Le risque du poste mal aligné

Un professionnel placé pendant dix-huit mois sur un poste qui n'exerce pas son socle subit une dépréciation réelle, non compensée par l'ancienneté. La réponse n'est pas la résignation ni la démission immédiate : c'est un **régime d'entretien explicite**, documenté et mesuré, mené en parallèle. Trois principes :

1. **Volume plancher.** Un bloc quotidien protégé, court mais non négociable (60 à 90 minutes), vaut mieux qu'une journée mensuelle. La régularité bat l'intensité sur les compétences composées.
2. **Preuve obligatoire.** Chaque session produit un artefact vérifiable — un commit, un test qui passe, un backtest chiffré, une note d'une page avec un résultat. Sans artefact, la session est comptée comme non faite. C'est la seule protection contre l'auto-illusion de progression.
3. **Notation anti-inflation.** Une échelle courte (0 à 3) avec une colonne « preuve » qui plafonne la note : on ne peut pas noter 3 une séance dont la preuve est un fichier vide. Les échelles longues invitent à la complaisance.

10.4. Le portefeuille, pas le poste

Le professionnel raisonne en portefeuille de compétences avec allocation explicite : - **60 % noyau** : approfondissement de la spécialité qui constitue sa rente. - **25 % adjacence** : compétences qui augmentent la valeur du noyau (pour un spécialiste séries temporelles : optimisation sous contrainte, supply chain, pricing). - **15 % option** : paris sur des domaines émergents, dont on accepte que 4 sur 5 ne servent jamais.

Une allocation à 100 % noyau produit un expert fragile ; une allocation à 100 % option produit un touriste permanent.

10.5. Refus associé

Refus n° 7 : je n'accepte pas qu'un contexte de poste devienne une excuse à la dépréciation. Si l'organisation ne me fournit pas les problèmes, je me les fournis — et je mesure.

PARTIE III — LE SOCLE TECHNIQUE : HUIT PILIERS

Chaque pilier est décrit selon la même structure : **ce qu'il faut savoir**, **ce qui distingue le confirmé de l'expert**, **les erreurs signatures**, **le critère de maîtrise vérifiable**.

11. Pilier 1 — Statistique et probabilité : le socle non commoditisable

11.1. Ce qu'il faut savoir

Le minimum non négociable, pour tout profil, quel que soit l'axe de spécialisation :

- **Variabilité d'échantillonnage.** Savoir qu'un écart observé peut être du bruit, et savoir estimer à partir de quelle taille il cesse de l'être. Un professionnel qui commente une variation de 2 % sur 300 observations sans intervalle commet une faute.
- **Distributions et leurs queues.** Loi normale, log-normale, Poisson, binomiale négative, Tweedie, Pareto. Savoir reconnaître les régimes à queue lourde, où la moyenne empirique est un estimateur instable et où les intuitions gaussiennes détruisent les décisions.
- **Biais de sélection sous toutes ses formes.** Survie, troncature, censure, non-réponse, auto-sélection. C'est le premier tueur silencieux de projet.
- **Comparaisons multiples.** Le contrôle du taux de fausses découvertes n'est pas un raffinement académique : dans un contexte où l'on teste couramment des centaines d'hypothèses (segments, variantes, features), l'absence de contrôle garantit la production de faux positifs, qui seront ensuite « validés » par le métier parce qu'ils racontent une histoire plausible.
- **Puissance statistique et dimensionnement.** Savoir dire *avant* une expérience combien d'observations sont nécessaires pour détecter l'effet minimal d'intérêt. Une expérience sous-dimensionnée n'est pas « peu concluante » : elle est un gaspillage prévisible.
- **Calibration et scoring rules propres** (Brier, log-loss, CRPS). Savoir qu'une métrique de scoring impropre encourage la malhonnêteté du modèle.
- **Le raisonnement bayésien élémentaire.** Non pas comme chapelle, mais comme discipline : quelle était ma croyance a priori, qu'apporte cette observation, quelle est ma croyance a posteriori. C'est le mécanisme qui protège contre l'adoption immédiate de résultats spectaculaires.

11.2. Confirmé vs expert

Confirmé	Expert
Applique un test statistique correctement	Sait qu'aucun test n'est nécessaire, ou que le test standard est invalide ici

Confirmé	Expert
Rapporte un p-value	Rapporte une taille d'effet avec incertitude, et discute la pertinence pratique
Connaît les hypothèses des méthodes	Sait laquelle est violée, dans quel sens, et quel biais cela induit
Détecte l'hétéroscédasticité	Sait quand elle est le signal et non le problème
Sait qu'il faut se méfier des données	Sait où précisément se méfier dans ce jeu de données-ci

11.3. Erreurs signatures

- Split aléatoire sur données temporelles ou groupées (le péché le plus fréquent et le plus destructeur).
- Choix de la métrique après observation des résultats.
- Utilisation du jeu de test pour ajuster un seuil, une feature ou un hyperparamètre — et ensuite, rapport de la performance sur ce même jeu.
- Interprétation de coefficients de modèles régularisés ou d'importances de features comme des effets causaux.
- Application d'un test paramétrique à des données dont la structure de dépendance viole l'indépendance (mesures répétées, panels, clusters géographiques).
- Confusion entre intervalle de confiance et intervalle de prédiction.

11.4. Critère de maîtrise vérifiable

Test : on présente au professionnel un résultat trop beau (uplift de 35 %, AUC de 0,96 sur un problème réputé difficile). Un expert produit en moins de cinq minutes une liste de trois à cinq mécanismes de fuite plausibles, classés par probabilité, et propose un test discriminant pour chacun. Un non-expert félicite ou demande des détails d'implémentation.

12. Pilier 2 — Inférence causale

12.1. Ce qu'il faut savoir

- **Le cadre des résultats potentiels** (Rubin) et le cadre graphique (Pearl). Les deux, pas l'un ou l'autre : le premier structure l'estimation, le second structure l'identification.
- **Les estimands.** ATE, ATT, ATU, CATE, LATE. Savoir lequel répond à la question posée. Une confusion d'estimand produit une réponse juste à une autre question — la forme d'erreur la plus difficile à détecter en relecture.
- **Les designs.** Expérimentation randomisée et ses variantes contraintes (switchback pour effets d'interférence temporelle, geo-experiments pour marketing, cluster-randomisation), DiD et estimateurs robustes à l'adoption échelonnée, contrôle synthétique, RDD, variables instrumentales.
- **Les méthodes d'ajustement modernes.** Double/debiased machine learning, forêts causales, meta-learners (S/T/X/R-learner), doublement robuste. Savoir que ces méthodes règlent le problème d'estimation, jamais celui d'identification.
- **L'uplift modeling** et son évaluation propre (courbe de Qini, uplift par décile), qui est un problème d'évaluation nettement plus subtil que la classification.
- **L'analyse de sensibilité** aux confondants non observés (bornes, E-value, sensibilité paramétrée).
- **Les interférences.** Effet de déversement entre unités, cannibalisation entre produits, équilibre général. Une promotion sur un produit modifie les ventes des substituts ; un test A/B sur une place de marché à deux versants viole SUTVA. Ignorer l'interférence

produit des estimations correctes localement et fausses globalement.

12.2. La discipline centrale : l'hypothèse rendue visible

L'expertise causale ne consiste pas à connaître plus d'estimateurs. Elle consiste à **rendre les hypothèses explicites, réfutables et discutables par des non-statisticiens**.

Un livrable causal de qualité contient toujours une section intitulée « Ce qui rendrait cette conclusion fausse », listant : - Les hypothèses d'identification, formulées en langage métier. - Pour chacune : ce qui la mettrait en défaut concrètement dans ce contexte. - Les tests de réfutation effectués et leurs résultats. - La force minimale d'un confondant non observé qui annulerait la conclusion.

Cette section est la signature de l'expert. Son absence est la signature de l'amateur, quel que soit le niveau de sophistication de l'estimateur employé.

12.3. Erreurs signatures

- Ajuster sur un médiateur (« on contrôle par le nombre de visites » quand la visite est le mécanisme de l'effet étudié).
- Ajuster sur un collider (sélectionner l'échantillon sur une conséquence commune du traitement et de l'issue).
- Utiliser un instrument faible ou non exclu (le test de force de l'instrument est obligatoire, l'exclusion est indémontrable et doit être argumentée).
- Appliquer le DiD classique en présence d'adoption échelonnée et d'effets hétérogènes : l'estimateur peut porter des poids négatifs et inverser le signe.
- Confondre significativité et pertinence économique.
- Présenter une SHAP value comme un effet causal. C'est aujourd'hui l'erreur la plus répandue de toute la profession.

12.4. Critère de maîtrise vérifiable

Test : « Nos ventes ont augmenté de 12 % après le lancement de la nouvelle politique tarifaire. Quel est l'effet ? » Un expert refuse de répondre et énonce ce qu'il lui faut : y a-t-il des unités non traitées comparables, l'adoption a-t-elle été simultanée, quelles autres actions ont eu lieu sur la période, la tendance pré-traitement est-elle parallèle, y a-t-il eu anticipation. Il propose ensuite deux designs alternatifs avec leurs hypothèses. Un non-expert calcule 12 %.

13. Pilier 3 — Séries temporelles et prévision

Traité en pilier autonome parce que c'est le domaine où les erreurs méthodologiques sont les plus systématiques et où le coût des erreurs est le plus directement chiffrable.

13.1. Ce qu'il faut savoir

- **Les régimes de données.** Série unique longue, panel de milliers de séries courtes, données intermittentes (beaucoup de zéros), séries hiérarchiques. Les méthodes appropriées diffèrent radicalement.
- **Les méthodes statistiques classiques,** qui restent des baselines redoutables : lissage exponentiel (famille ETS), ARIMA saisonnier, Theta, méthodes intermittentes (Croston et ses variantes corrigées). Leur robustesse en petit échantillon reste inégale.
- **Les modèles globaux** entraînés sur l'ensemble des séries — gradient boosting sur features de retard et de calendrier, modèles profonds spécialisés. Le passage du local

au global est le changement de paradigme majeur des dix dernières années : sur un panel de milliers de séries, un modèle global correctement construit domine presque toujours l'ensemble des modèles locaux.

- **Les modèles profonds temporels** et les modèles de fondation pré-entraînés pour la prévision. Utiles en zéro-shot pour établir rapidement une borne, rarement supérieurs à un modèle global bien conçu sur données propriétaires.
- **La réconciliation hiérarchique.** Quand on prévoit par produit, par magasin, par région et au total, les prévisions doivent être cohérentes. Les méthodes de réconciliation optimale (MinT et variantes) améliorent presque toujours la précision *à tous les niveaux*, pas seulement la cohérence. Point sous-exploité.
- **Les exogènes.** Calendrier (jours fériés et leurs veilles/lendemain, vacances scolaires par zone, ponts, position dans le mois, effets de paie), météo, prix, promotions, ruptures de stock passées. La modélisation calendaire fine est le gisement de gain le plus rentable et le plus négligé dans l'industrie française.
- **L'évaluation temporelle.** Validation à origine roulante, horizons multiples, agrégation correcte des erreurs. Une prévision à $h=1$ et $h=52$ ne s'évalue pas de la même façon et ne sert pas la même décision.
- **Les métriques.** MAPE (invalide près de zéro, asymétrique, encourage la sous-prévision), WMAPE (pondérée par le volume — souvent le bon défaut en distribution), MASE (comparable entre séries, référencée à la naïve), RMSSE, pinball loss pour les quantiles, CRPS pour les distributions.

13.2. Les cinq erreurs qui coûtent le plus cher

1. **La fuite temporelle.** Utiliser une information non disponible au moment de la prévision. Formes courantes : moyennes calculées sur l'ensemble de la série, normalisation globale, features construites sur des tables mises à jour rétroactivement, prix « du jour » qui est en réalité le prix final après remise. Impact typique : des performances de backtest deux à cinq fois meilleures que la réalité en production.
2. **L'oubli de la normalisation du parc.** Prévoir un volume d'événements sans normaliser par la population exposée revient à modéliser la croissance de la population plutôt que le phénomène. Erreur systématique dans les métiers de service et de maintenance.
3. **La contamination par les ruptures.** Les ventes observées ne sont pas la demande : elles sont le minimum entre demande et disponibilité. Entraîner sur les ventes brutes en présence de ruptures fait apprendre au modèle à reproduire les ruptures. Le traitement (censure, reconstruction de la demande latente) est indispensable dès que le taux de rupture dépasse quelques pourcents.
4. **L'évaluation à horizon unique.** Un modèle optimal à $h=1$ peut être médiocre à $h=13$, qui est pourtant l'horizon de décision réel du planificateur.
5. **L'ignorance de la décision aval.** Optimiser une erreur symétrique pour alimenter une décision de stock asymétrique. Voir Axiome II.

13.3. Confirmé vs expert

Confirmé	Expert
Compare cinq modèles sur un backtest	Construit d'abord le protocole d'évaluation, puis compare
Ajoute des features calendaires	Modélise les effets mobiles, les veilles et lendemains, les interactions jour-férié × type de point de vente
Rapporte un MAPE global	Rapporte l'erreur par segment de volume, par horizon, et identifie où se concentre le coût

Confirmé	Expert
Améliore le modèle	Détermine d'abord si le problème est limité par le signal, puis décide d'améliorer le modèle ou de chercher des données
Livre des prévisions	Livre des prévisions, des quantiles, un diagnostic de dérive et une procédure de reprise manuelle

13.4. Critère de maîtrise vérifiable

Test : on donne un backtest montrant qu'un modèle sophistiqué bat la naïve saisonnière de 30 %. Un expert demande immédiatement : la validation est-elle à origine roulante, les features sont-elles disponibles à la date de prévision, y a-t-il des ruptures dans l'historique, le gain est-il uniforme ou porté par quelques séries, et que donne la comparaison en MASE plutôt qu'en MAPE. Il trouve la fuite dans plus de la moitié des cas.

14. Pilier 4 — Ingénierie logicielle : le vrai delta

14.1. Pourquoi c'est devenu le pilier séparateur

Puisque la génération de code est gratuite, **la valeur s'est déplacée vers la capacité à maintenir du code que l'on n'a pas écrit**. C'est exactement la compétence d'ingénierie logicielle : structuration, tests, revue, refactoring, gestion de dépendances, lecture de code étranger.

Un professionnel qui produit du code généré sans structure d'accueil produit une dette technique à une vitesse inédite. Le phénomène est déjà mesurable : volume de code en forte hausse, duplication en hausse, ratio de code supprimé en baisse. L'assistant amplifie ce qu'on lui donne : sur une base propre, il accélère ; sur une base sale, il aggrave.

14.2. Ce qu'il faut savoir

- **Contrôle de version pour de vrai.** Branches courtes, commits atomiques avec message expliquant le *pourquoi*, revue de code systématique, historique lisible. Un dépôt dont l'historique n'est pas lisible n'est pas versionné, il est sauvegardé.
- **Tests.** Unitaires sur la logique métier, tests de propriété sur les transformations, tests d'intégration sur la chaîne, tests de données sur les entrées, tests de non-régression sur les sorties du modèle. Le test le plus rentable en data science n'est pas le test unitaire : c'est **le test de données**.
- **Structuration.** Séparation stricte entre configuration, logique de transformation, logique de modélisation, et interface. Aucune valeur codée en dur. Aucun chemin absolu. Aucun secret dans le code.
- **Environnements reproductibles.** Verrouillage des dépendances, conteneurisation, exécution identique en local et en CI. La phrase « ça marche chez moi » est une déclaration d'échec d'ingénierie.
- **Typage et validation.** Annotations de type, validation de schéma aux frontières. C'est la protection la moins coûteuse et la plus efficace contre les erreurs silencieuses.
- **Lecture de code.** Compétence rarement enseignée, devenue centrale : savoir comprendre rapidement une base de code inconnue, identifier où intervenir, évaluer le risque d'une modification.
- **Journalisation et observabilité applicative.** Logs structurés, identifiants de corrélation, métriques d'exécution. Un système qu'on ne peut pas déboguer en production est un système qu'on devra réécrire.

14.3. La règle de la revue inversée

Pratique de discipline pour l'ère des assistants : **tout code généré est relu comme si son auteur était un inconnu peu fiable, avant d'être commité.** Concrètement :

1. Le professionnel écrit d'abord le test ou la spécification, puis fait générer l'implémentation.
2. Il relit intégralement, en cherchant activement : gestion d'erreur absente, hypothèses implicites sur les données, complexité algorithmique cachée, dépendance inutile ajoutée, comportement silencieux en cas d'entrée vide ou nulle.
3. Il exécute sur un cas limite qu'il a lui-même construit.
4. Il ne committe jamais de code qu'il ne saurait pas réécrire.

Le point 4 est le critère déontologique de l'ère générative.

14.4. Erreurs signatures

- Notebooks en production, orchestrés par un outil qui les exécute tels quels.
- Fonctions de plus de cent lignes mélangeant lecture de données, transformation et modélisation.
- Aucun test, avec justification « c'est de la data science, ça ne se teste pas » — affirmation fausse : la logique métier, les transformations et les invariants de données sont hautement testables.
- Configuration dispersée dans le code.
- Dépendance à un état local (fichiers sur le poste, variables d'environnement non documentées).
- Copier-coller entre projets plutôt qu'extraction d'un package interne.

14.5. Critère de maîtrise vérifiable

Test : on demande de reprendre un projet écrit par quelqu'un d'autre, non documenté, et d'y ajouter une fonctionnalité. Un professionnel solide commence par le faire tourner, écrit un test caractérisant le comportement actuel, puis modifie. Un professionnel faible commence à réécrire.

15. Pilier 5 — Data engineering analytique et contrats de données

15.1. Position du pilier

Le Data Scientist de 2026 n'est pas un Data Engineer, mais il est **autonome sur la couche analytique**. La frontière utile est la suivante :

- **Ce qu'il ne fait pas** : ingestion temps réel, gestion de clusters, optimisation de moteurs distribués, réseau, sécurité d'infrastructure.
- **Ce qu'il fait obligatoirement** : modélisation analytique (couches staging / intermédiaire / marts), tests de données, documentation, gestion de l'incrémental, gestion de l'historisation, optimisation de coût de requêtes.

Un professionnel incapable de construire lui-même sa couche de données dépend d'un tiers pour chaque itération, ce qui multiplie par trois à cinq son cycle de travail. C'est la première cause de lenteur perçue des équipes data.

15.2. Ce qu'il faut savoir

- **SQL analytique avancé.** Fonctions de fenêtre, agrégations conditionnelles, jointures temporelles (as-of joins), gestion des doublons, requêtes récursives. SQL n'est pas une compétence junior : c'est le langage dans lequel s'écrit la définition métier de l'entreprise.
- **Modélisation dimensionnelle** et ses alternatives. Faits, dimensions, grain, granularité. La question « quel est le grain de cette table ? » est la question la plus discriminante qu'on puisse poser sur un modèle de données. Une table dont le grain n'est pas déclaré produira des doubles comptages.
- **L'historisation.** Dimensions à évolution lente, tables de snapshot, capture de changement. **Point critique pour la data science :** l'immense majorité des tables d'entreprise sont écrasées à chaque mise à jour, ce qui rend impossible la reconstruction de l'état du monde à une date passée — et donc impossible la construction d'un jeu d'entraînement honnête. Le professionnel identifie ce problème *au cadrage*, pas au moment de la modélisation.
- **Transformation déclarative et testée** (dbt ou équivalent) : modèles versionnés, tests de schéma et de logique métier, documentation générée, lignage explicite, matérialisations incrémentales, CI qui ne reconstruit que l'impacté.
- **Contrats de données.** Schéma, sémantique, fraîcheur, complétude, propriétaire, procédure de changement. Un contrat sans propriétaire nommé et sans procédure de rupture n'est pas un contrat.
- **Qualité de données.** Tests d'unicité, de non-nullité, de référentialité, de plage de valeurs, de volumétrie attendue, de fraîcheur. Et surtout : **des tests métier** — « la somme des lignes de commande égale le total commande à 0,01 près », « aucun client n'a deux contrats actifs simultanés ».
- **Coût.** Sur les entrepôts facturés à la donnée scannée, la différence entre une requête naïve et une requête partitionnée/clusterisée est d'un facteur 10 à 1000. Le coût est une contrainte de conception, pas une découverte de fin de mois.

15.3. Le point aveugle le plus coûteux : la définition métier

Les conflits de chiffres entre services ne viennent presque jamais d'erreurs de calcul. Ils viennent de définitions divergentes : qu'est-ce qu'un « client actif », une « commande », un « chiffre d'affaires » (avec ou sans remises, avec ou sans annulations, à quelle date de rattachement).

Le professionnel qui règle cela produit plus de valeur que celui qui gagne trois points d'AUC. Concrètement : une couche de définitions certifiées, un propriétaire métier par définition, et le refus de recalculer localement une grandeur déjà définie ailleurs.

15.4. Erreurs signatures

- Recalculer une métrique existante dans son coin, produisant un chiffre différent de celui du reporting officiel — puis passer trois semaines à justifier l'écart.
- Construire des features à partir de tables écrasées, sans se demander si l'état passé est reconstituable.
- Jointures sans vérification de cardinalité, produisant une explosion de lignes non détectée.
- Absence de test de fraîcheur : le modèle tourne, les données sont figées depuis six jours, personne ne le sait.
- Pipelines non idempotents : une réexécution produit des doublons.

15.5. Critère de maîtrise vérifiable

Test : on demande le chiffre d'affaires du mois dernier. Un professionnel solide demande : selon quelle définition, à quelle date de rattachement, périmètre inclus, traitement des avoirs et annulations, devise et taux de conversion. Puis il indique quelle table certifiée fait foi. Un professionnel faible écrit une requête.

16. Pilier 6 — MLOps et plateforme

16.1. Ce qu'il faut savoir

Le MLOps n'est pas une collection d'outils, c'est un ensemble de propriétés à garantir. Les outils changent tous les trois ans, les propriétés jamais.

Les six propriétés :

1. **Reproductibilité.** Étant donné un identifiant de version, on peut reconstruire à l'identique le modèle, ses données d'entraînement, son code et son environnement. Cela exige le versionnement conjoint code + données + configuration + environnement.
2. **Traçabilité.** Pour toute prédiction en production, on peut retrouver le modèle qui l'a produite, les features utilisées et leurs valeurs, et la date. C'est une exigence réglementaire croissante autant qu'un impératif de débogage.
3. **Automatisation.** Le passage de l'entraînement à la production ne comporte aucune étape manuelle. Une étape manuelle est une étape qui sera oubliée.
4. **Observabilité.** On mesure en continu : disponibilité, latence, débit, coût, distribution des entrées, distribution des sorties, performance réelle dès que la vérité terrain arrive.
5. **Réversibilité.** On peut revenir à la version précédente en quelques minutes, sans réentraînement.
6. **Gouvernance.** Chaque modèle a un propriétaire, une documentation, une date de revue, un statut (candidat / production / déprécié) et une décision de fin de vie.

16.2. Le monitoring qui compte

Le monitoring de modèle est presque toujours mal fait : on surveille la dérive des features, ce qui produit beaucoup d'alertes et peu d'informations. La hiérarchie utile, du plus important au moins important :

1. **La performance réelle,** mesurée contre la vérité terrain quand elle arrive (avec le délai correspondant). C'est le seul indicateur qui compte vraiment.
2. **La qualité et la fraîcheur des entrées.** La majorité des incidents ML ne sont pas des dérives de concept : ce sont des pannes de pipeline amont, des changements de schéma non annoncés, des valeurs par défaut qui remplacent silencieusement des valeurs manquantes.
3. **La distribution des sorties.** Un décalage brutal de la distribution des prédictions est le signal le plus rapide d'un problème amont.
4. **Le comportement d'usage.** Taux d'override par les utilisateurs, taux d'ignorance de la recommandation. Un modèle ignoré à 80 % est un modèle mort, quelle que soit sa performance.
5. **La dérive des features.** Utile en dernier recours, à condition d'être segmentée et seuillée intelligemment. Non segmentée, elle produit du bruit.

16.3. Le réentraînement

Le réentraînement périodique automatique sans garde-fou est une pratique dangereuse : il propage silencieusement les problèmes de données récentes dans le modèle. Le protocole correct :

- Réentraînement déclenché par le calendrier **ou** par une dégradation détectée.
- Validation automatique du nouveau modèle contre l'ancien sur un jeu de contrôle, avec critère de promotion défini à l'avance.
- Promotion progressive (shadow, puis canari sur un pourcentage du trafic, puis complet).
- Conservation de l'ancien modèle et possibilité de retour immédiat.
- Journal des promotions avec justification chiffrée.

16.4. L'échelle : la règle de proportionnalité

Une critique fréquente et fondée du MLOps est le sur-outillage. Trois régimes :

Contexte	Outillage justifié
1-3 modèles, batch, faible criticité	Dépôt versionné, tests, conteneur, orchestrateur simple, alerte par mail, suivi d'expériences léger
5-30 modèles, mixte batch/temps réel	Registre de modèles, CI/CD complète, monitoring structuré, feature store si réutilisation réelle, environnements séparés
50+ modèles, plusieurs équipes	Plateforme interne, standards imposés, catalogue, gouvernance formalisée, self-service

Déployer l'outillage du troisième régime dans le premier est une faute de jugement coûteuse et fréquente. **Le feature store, en particulier, est justifié par la réutilisation entre équipes et la cohérence entraînement/inférence, pas par la mode.**

16.5. Critère de maîtrise vérifiable

Test : « Ton modèle produit depuis ce matin des prédictions aberrantes. Que fais-tu, dans l'ordre ? » Réponse attendue : je bascule sur le mode dégradé ou la version précédente *d'abord* (limiter l'impact), je préviens les consommateurs, puis seulement j'investigue en commençant par les entrées et non par le modèle, je vérifie fraîcheur et schéma amont, je compare la distribution des features à celle d'hier, j'identifie, je corrige, j'ajoute un test qui aurait détecté le problème, j'écris un post-mortem sans recherche de coupable.

17. Pilier 7 — LLMOps, évaluation et systèmes agentiques

17.1. Le changement de nature

Un système à base de modèles de langage diffère d'un système ML classique sur cinq points qui invalident les réflexes acquis :

1. **Non-déterminisme.** La même entrée peut produire des sorties différentes. Les tests d'égalité exacte sont inapplicables.
2. **Espace de sortie non structuré.** Il n'y a pas de métrique naturelle. Il faut *construire* la métrique, ce qui est le cœur du travail.
3. **Dépendance à un fournisseur externe.** Le modèle change sous vos pieds, sans préavis équivalent à un changement de version logicielle. La régression silencieuse est un risque permanent.
4. **Surface d'attaque nouvelle.** Injection de prompt, exfiltration de données via le contexte, abus d'outils, empoisonnement de la base documentaire.
5. **Coût variable à l'usage.** Le coût unitaire devient une contrainte de conception au même titre que la latence.

17.2. L'évaluation : le cœur du métier

La compétence centrale de l'ingénieur en systèmes d'IA n'est pas le **prompt engineering**. C'est la **construction d'un dispositif d'évaluation crédible**. Un prompt se réécrit en dix minutes ; un jeu d'évaluation représentatif se construit en trois semaines et constitue l'actif durable.

Architecture d'évaluation minimale :

- **Un jeu d'évaluation** constitué de cas réels, échantillonnés pour couvrir la distribution d'usage *et* les cas limites. Cinquante cas bien choisis valent mieux que mille cas générés artificiellement.
- **Des cas d'échec connus** — chaque incident de production devient un cas de test permanent. C'est le mécanisme de non-régression.
- **Des métriques par niveau** : au niveau de la tâche complète (le système a-t-il réussi ?), au niveau des composants (la recherche a-t-elle ramené le bon document ? l'outil a-t-il été appelé avec les bons arguments ?), au niveau du coût et de la latence.
- **Une combinaison de juges** : vérifications déterministes quand c'est possible (format, présence d'un identifiant, validité d'un JSON, exactitude d'un calcul), juge automatique par modèle pour les jugements qualitatifs, revue humaine sur un échantillon.
- **La calibration du juge automatique**. Un juge non validé contre des annotations humaines est un générateur de chiffres rassurants. Il faut mesurer l'accord juge/humain, et le remesurer après chaque changement.
- **Une exécution en intégration continue**, avec seuils de blocage. Un changement de prompt qui dégrade le jeu d'évaluation ne passe pas.

17.3. La conception des systèmes agentiques

Doctrines de sobriété, apprises à ses dépens par l'ensemble du secteur entre 2024 et 2026 :

- **Le déterminisme d'abord**. Tout ce qui peut être un appel de fonction classique, une règle ou un flux fixe doit l'être. L'autonomie du modèle est réservée aux points où elle est indispensable. Un « agent » qui décide de tout est un système dont on ne peut ni prédire le coût ni garantir le comportement.
- **La décomposition en étapes vérifiables**. Chaque étape produit une sortie contrôlable. L'erreur composée est le tueur des chaînes longues : dix étapes à 95 % de fiabilité produisent 60 % de fiabilité globale. C'est le calcul que trop peu d'équipes font avant de concevoir.
- **L'ingénierie du contexte** plutôt que l'ingénierie du prompt : que met-on dans la fenêtre, dans quel ordre, avec quelle compression, quelle mémoire persistante, quelle stratégie de récupération. C'est là que se joue la qualité, pas dans la formulation des instructions.
- **Les garde-fous**. Limites d'itérations, budget maximal par tâche, périmètre d'outils restreint par le principe de moindre privilège, validation humaine obligatoire sur les actions irréversibles, journalisation intégrale des appels d'outils.
- **La boucle de rattrapage**. Tout système autonome doit avoir un chemin d'escalade vers l'humain, avec un critère d'escalade explicite (faible confiance, cas hors distribution, montant supérieur à un seuil, échec répété).

17.4. L'arbitrage coût / latence / qualité

Compétence spécifique et très demandée. Les leviers, par ordre de rentabilité habituelle :

1. **Routage par difficulté** : petit modèle par défaut, escalade vers un grand modèle sur les cas difficiles détectés. Gain typique de 60 à 80 % du coût à qualité constante.

2. **Mise en cache** (exacte, sémantique, ou du préfixe de contexte). Gain massif sur les usages répétitifs.
3. **Compression du contexte** : ne pas envoyer ce qui n'est pas utile. Le contexte long dégrade la qualité *et* le coût simultanément.
4. **Réduction du nombre d'appels** : fusionner des étapes, éviter les boucles de réflexion inutiles.
5. **Distillation ou ajustement fin léger** sur les tâches à fort volume et faible variabilité. Justifié à partir d'un seuil de volume, pas avant.
6. **Traitement par lot** pour tout ce qui n'est pas interactif.

Le professionnel présente ces arbitrages sous forme de frontière : « à ce niveau de qualité, voici le coût unitaire ; pour gagner 3 points, le coût triple ». C'est une conversation économique, pas technique.

17.5. Erreurs signatures

- Démonstration sur cinq cas présentée comme un système.
- Absence de jeu d'évaluation, remplacé par « ça a l'air bien ».
- Juge automatique non calibré.
- Chaîne à quinze étapes autonomes sans calcul d'erreur composée.
- Outils dotés de permissions larges « pour simplifier ».
- Absence de mesure de coût unitaire, découverte à la première facture.
- Empilement d'un agent là où une requête SQL suffisait.

17.6. Critère de maîtrise vérifiable

Test : « Ton système de support automatique passe de 78 % à 71 % de réussite après une mise à jour du modèle fournisseur. Comment le sais-tu, et que fais-tu ? » Un expert répond qu'il le sait parce que le jeu d'évaluation tourne en continu et a alerté ; il épingle la version du modèle, analyse les cas de régression par catégorie, ajuste ou reste sur l'ancienne version, et ajoute les cas de régression au jeu permanent. Un non-expert découvre le problème par les réclamations clients.

18. Pilier 8 — Économie de la décision

18.1. Le pilier manquant de la formation standard

C'est le pilier le plus absent des cursus et le plus déterminant en pratique. Un modèle produit une estimation ; une décision requiert en plus une fonction d'objectif, des contraintes et une règle d'arbitrage sous incertitude.

18.2. Ce qu'il faut savoir

- **Théorie de la décision élémentaire.** Espérance d'utilité, coût d'opportunité, valeur de l'information. La question « combien vaudrait une information parfaite ici ? » borne l'investissement analytique et évite des projets entiers.
- **Optimisation sous contrainte.** Programmation linéaire et en nombres entiers, affectation, ordonnancement, tournées. Énormément de demandes formulées comme « prédictives » sont en réalité des problèmes d'optimisation dont la partie prédictive est marginale. Savoir reconnaître cela évite de résoudre le mauvais problème.
- **Le paradigme « prédire puis optimiser » et ses limites.** L'optimisation aval amplifie les erreurs de prédiction de façon asymétrique ; les approches intégrées

(apprentissage orienté décision) existent et méritent d'être connues, même si elles restent rarement nécessaires.

- **Économie appliquée.** Élasticité-prix, effets de cannibalisation et de halo, coût marginal, marge de contribution, effets de seuil dans les remises. Un modèle de pricing construit sans compréhension de la structure de marge produit des recommandations destructrices de valeur.
- **Gestion des stocks et théorie du newsvendor.** Quantile critique, coût de rupture, coût de possession, stock de sécurité comme fonction de l'incertitude de la prévision *et* de l'incertitude du délai d'approvisionnement.
- **Finance élémentaire.** Valeur actuelle nette, retour sur investissement, besoin en fonds de roulement. Savoir traduire une amélioration opérationnelle en effet sur le compte de résultat ou sur le bilan est ce qui rend un professionnel audible en comité de direction.

18.3. La chaîne de valeur complète

Un professionnel de haut niveau sait dérouler cette chaîne devant un dirigeant, sans notes :

Modèle → réduction d'erreur mesurée → modification de la règle de décision → changement de comportement opérationnel → effet sur un poste de coût ou de revenu → effet sur le résultat annuel → intervalle d'incertitude sur cet effet → conditions de réalisation.

Quatre-vingt-dix pour cent des professionnels s'arrêtent à la deuxième flèche. La différence de rémunération entre ceux qui s'arrêtent là et ceux qui vont au bout est d'un facteur substantiel, et croissante.

18.4. Critère de maîtrise vérifiable

Test : « Ton modèle réduit l'erreur de prévision de 3 points. Et alors ? » Un expert répond en trois phrases avec un ordre de grandeur en euros, la décision opérationnelle modifiée, et les conditions sous lesquelles ce gain se matérialise (adoption réelle, absence de compensation manuelle, paramétrage du stock de sécurité effectivement ajusté). Un non-expert répond « c'est mieux ».

PARTIE IV — CE QUI SÉPARE LE BON DU DÉCISIF

Les huit piliers décrivent un professionnel compétent. Ce qui suit décrit ce qui le rend décisif. C'est la partie que les professionnels techniques négligent le plus longtemps, et celle dont ils regrettent le plus la négligence.

19. Le cadrage : l'art de la question

19.1. La règle des dix pour cent

Dix pour cent du temps total d'un projet doit être consacré à la formulation de la question, avant toute ouverture de données. Sur un projet de dix semaines, cela fait quatre à cinq jours. Cette allocation paraît excessive à tous ceux qui ne l'ont jamais pratiquée, et insuffisante à tous ceux qui l'ont pratiquée.

19.2. La traduction en trois passes

Passe 1 — Ce qui est demandé. On écrit la demande telle qu'elle a été formulée, mot pour mot. « On voudrait de l'IA pour améliorer nos prévisions. »

Passe 2 — Le problème réel. On remonte à la douleur. Questions : que se passe-t-il aujourd'hui qui vous coûte ? Depuis quand ? Qui s'en plaint ? Qu'avez-vous déjà essayé et pourquoi cela n'a pas marché ? Si on ne fait rien, quelle est la conséquence dans six mois ? Réponse typique : « les planificateurs corrigent 70 % des prévisions à la main, ils y passent deux jours par semaine, et personne ne sait si leurs corrections améliorent ou dégradent ».

Ce n'est plus le même projet. Le problème n'est pas la précision : c'est la confiance et le temps humain. La première action utile n'est pas de modéliser, c'est de **mesurer la valeur ajoutée des corrections manuelles** — analyse d'une semaine, qui change souvent complètement la suite.

Passe 3 — La question traitable. Une question traitable a cinq attributs obligatoires : une unité d'analyse, une population, une fenêtre temporelle, une grandeur à estimer, un critère de succès chiffré. Exemple : « Sur les 400 références du périmètre frais, en prévision hebdomadaire à horizon 1 à 4 semaines, sur les 12 derniers mois en validation à origine roulante, réduire le WMAPE pondéré volume d'au moins 15 % relatif par rapport à la prévision actuelle post-correction manuelle. »

19.3. Les questions de cadrage qui font mal

Les bonnes questions de cadrage sont celles qui mettent le commanditaire mal à l'aise. Elles révèlent l'absence de décision, le désaccord interne, ou l'inexistence des données.

- Qui, nommément, changera son comportement grâce à ce système ?

- Que fera cette personne différemment lundi matin ?
- Qui perd quelque chose si ce projet réussit ?
- Si le résultat contredit l'intuition de la direction, qu'advient-il ?
- Quelle est la décision par défaut aujourd'hui, et quelle est sa performance mesurée ?
- Quel est le délai entre la décision et l'observation de son résultat ?
- Y a-t-il un historique fiable de ce qui a été *décidé*, ou seulement de ce qui a été *observé* ?
- À quelle date ce projet doit-il être mort si les résultats ne sont pas au rendez-vous ?

La dernière est la plus importante et la plus rarement posée.

19.4. Le pré-mortem

Avant de démarrer : réunir les parties prenantes et poser la question « nous sommes dans un an, le projet a échoué, que s'est-il passé ? ». En vingt minutes, on obtient la liste des risques réels, formulée par ceux qui les connaissent. Cette liste devient le registre de risques du projet, avec une action de mitigation par ligne.

C'est le dispositif de cadrage au meilleur rapport coût / valeur qui existe.

20. La narration quantitative

20.1. Le principe fondamental

Un résultat non compris n'existe pas. La qualité d'un travail analytique est plafonnée par la capacité du destinataire à s'en servir. Un professionnel qui produit un excellent travail incompréhensible produit zéro valeur, exactement comme celui qui produit un mauvais travail.

Cette affirmation heurte, parce qu'elle place la communication au même rang que la rigueur. C'est pourtant la seule position tenable : les deux sont des conditions nécessaires, aucune n'est suffisante.

20.2. La structure imposée

Tout livrable écrit suit la même structure, sans exception :

1. **La réponse, en une phrase.** Pas le contexte, pas la méthode : la réponse.
2. **La recommandation, en une phrase.** Ce qu'il faut faire.
3. **Les trois chiffres qui la portent.** Trois, pas douze.
4. **L'incertitude et ses conséquences.** Dans quelle fourchette, et à partir de quelle borne la recommandation changerait.
5. **Ce qui invaliderait la conclusion.** Les hypothèses, en langage métier.
6. **La méthode.** En annexe. Toujours en annexe.

L'ordre inverse — contexte, données, méthode, résultats, conclusion — est l'ordre du mémoire académique. Il est inadapté à la décision, parce qu'il oblige le décideur à lire jusqu'au bout pour savoir si cela le concerne. Il est aussi, subtilement, un mécanisme de protection : en noyant la conclusion, on réduit le risque d'être contredit. Le professionnel de 2026 y renonce.

20.3. Les règles de graphique

- Un graphique, un message. Le titre du graphique est le message, pas la description des axes. « Les ruptures se concentrent sur 8 % des références » plutôt que « Taux de rupture par référence ».
- L'incertitude est représentée, toujours. Une courbe de prévision sans bande est un mensonge visuel.

- L'échelle n'est jamais tronquée pour dramatiser un effet.
- La comparaison est explicite : par rapport à quoi, à quand, à qui.
- Pas plus de deux niveaux d'information par visuel.

20.4. Parler à trois publics

Le même résultat se raconte de trois façons, et le professionnel complet sait les trois :

Public	Ce qui l'intéresse	Durée	Registre
Opérationnel	Ce que ça change dans son travail quotidien, ce qui se passe quand c'est faux	10 min	Concret, cas d'usage, exemples réels
Management	L'effet sur ses objectifs, le risque, le coût, le calendrier	5 min	Chiffres, arbitrages, décisions à prendre
Direction	L'ordre de grandeur, la position concurrentielle, ce qu'on demande	2 min	Une phrase, un chiffre, une demande

L'erreur la plus commune est de servir le registre technique aux trois. La deuxième est de servir le registre direction à l'opérationnel, qui a besoin de détail pour faire confiance.

20.5. L'honnêteté comme actif de long terme

Dire « je ne sais pas », « ce chiffre est fragile », « mon modèle ne bat pas la règle actuelle » a un coût immédiat et un rendement composé. La réputation d'un professionnel analytique repose entièrement sur le fait que ses chiffres n'ont jamais eu à être repris. Une seule surestimation défendue produit une décote durable sur tout ce qu'il dira ensuite.

Corollaire : annoncer soi-même ses erreurs, avant qu'elles ne soient découvertes, avec la correction et la mesure préventive. C'est l'acte qui construit le plus rapidement l'autorité professionnelle.

21. La négociation du périmètre et l'art du refus

21.1. Pourquoi le refus est une compétence technique

Un professionnel qui accepte tout produit un travail dilué, sans hiérarchie, et perd sa capacité à garantir quoi que ce soit. Le refus n'est pas une posture : c'est le mécanisme par lequel on protège la qualité de ce qu'on livre.

Un refus professionnel a toujours trois composantes : **le motif** (technique, pas personnel), **le coût évité** (ce que le demandeur économise), **l'alternative** (ce qu'on propose à la place). Un refus sans alternative est un abandon.

21.2. Les douze refus documentés

1. **Le projet sans décision cible.** → Alternative : atelier de cadrage d'une demi-journée.
2. **La demande de technologie plutôt que de résultat** (« faisons de l'IA »). → Alternative : identification de trois cas d'usage chiffrés, sélection d'un.
3. **Le modèle sans baseline mesuré.** → Alternative : mesurer d'abord la performance de la pratique actuelle.
4. **La causalité sur données observationnelles sans design.** → Alternative : proposer un design expérimental, ou livrer avec avertissement explicite.

5. **La promesse de performance avant exploration des données.** → Alternative : engagement sur une phase de faisabilité chiffrée avec critère de poursuite.
6. **Le déploiement sans propriétaire nommé.** → Alternative : ne pas déployer tant que le nom n'est pas écrit.
7. **La conclusion sur échantillon insuffisant.** → Alternative : indiquer la taille nécessaire, proposer une collecte.
8. **La modification de méthode pour obtenir le résultat attendu.** → Refus sans alternative. C'est une ligne rouge.
9. **Le projet dont les données d'entraînement n'existent pas historiquement** (tables écrasées, pas d'historisation). → Alternative : mettre en place l'historisation maintenant, revenir dans douze mois.
10. **La demande de retirer les intervalles d'incertitude « pour simplifier ».** → Alternative : simplifier la représentation, pas l'information.
11. **Le maintien d'un système que personne n'utilise.** → Alternative : l'éteindre, et documenter pourquoi.
12. **Le sur-outillage** (plateforme complète pour deux modèles). → Alternative : dimensionner à l'échelle réelle, prévoir le chemin de croissance.

21.3. La négociation par le coût, jamais par le refus sec

Formule opératoire : ne jamais dire « non », dire « oui, et voici ce que cela déplace ».

« Oui, c'est faisable. Cela ajoute trois semaines et repousse la mise en production de la prévision hebdomadaire au 15 novembre. Voulez-vous cet arbitrage, ou préférez-vous que nous livrions d'abord et ajoutions cela en version 2 ? »

Cette formulation transfère la décision d'arbitrage à celui qui a le mandat de la prendre, ce qui est à la fois plus respectueux et plus efficace. Elle transforme un conflit de personnes en décision de gestion.

21.4. L'engagement sur le processus, jamais sur le résultat

Un professionnel ne s'engage jamais sur une valeur de performance avant d'avoir vu les données. Il s'engage sur : - Un protocole d'évaluation honnête. - Une date de verdict. - Un critère de poursuite ou d'arrêt défini à l'avance. - La transparence complète sur les résultats intermédiaires.

Cette discipline, appliquée systématiquement, est ce qui distingue un professionnel d'un vendeur.

22. Éthique opérationnelle, conformité, gouvernance

22.1. Le contexte réglementaire européen en 2026

Le professionnel exerçant en Europe connaît l'état du cadre, parce qu'il conditionne la conception, pas seulement la documentation.

- Le règlement européen sur l'IA est entré en vigueur le 1er août 2024 et s'applique par vagues.
- L'obligation de **littératie en IA** — savoir démontrer que les équipes ont été formées aux possibilités, limites et risques des systèmes utilisés — s'applique depuis février 2025 et est devenue pleinement contrôlable en 2026.
- Les obligations relatives aux **modèles à usage général** s'appliquent depuis août 2025.

- Les **obligations de transparence de l'article 50** — informer les personnes qu'elles interagissent avec une IA, marquer les contenus générés — sont applicables depuis le 2 août 2026.
- Le calendrier des **systèmes à haut risque** a été modifié en cours d'année par le paquet dit « Digital Omnibus » : les obligations de l'annexe III sont repoussées à décembre 2027, celles relevant des produits soumis à évaluation de conformité à 2028. Le report ne change pas la substance des obligations, il change la date.
- Les sanctions maximales atteignent 35 M€ ou 7 % du chiffre d'affaires mondial selon l'infraction, calculées au niveau du groupe.
- Le RGPD continue de s'appliquer intégralement en parallèle dès qu'il y a des données personnelles.

Point de doctrine : le report des échéances n'est pas une autorisation à différer. Les exigences de fond — gestion des risques, qualité des données, documentation technique, journalisation, supervision humaine, robustesse — sont exactement ce qu'un système bien conçu doit avoir de toute façon. Les organisations qui les traitent comme une contrainte de conformité tardive les paieront deux fois.

(État au moment de la rédaction, août 2026 ; le calendrier a bougé plusieurs fois en dix-huit mois, une vérification est nécessaire avant toute décision engageante.)

22.2. Les questions à se poser sur chaque projet

Cinq questions, systématiquement, dès le cadrage :

1. **Qui subit une décision de ce système sans l'avoir choisi ?** C'est la question qui détermine le niveau d'exigence.
2. **Quelle est l'erreur la plus grave possible, et qui la subit ?** Un faux positif sur une détection de fraude qui bloque un compte, un faux négatif sur une maintenance qui blesse un opérateur.
3. **Le système reproduit-il une discrimination présente dans l'historique ?** Un modèle entraîné sur des décisions humaines passées apprend les biais de ces décisions. C'est mécanique, pas hypothétique.
4. **La personne concernée peut-elle comprendre et contester ?** Explicabilité et voie de recours.
5. **Que se passe-t-il si le système est détourné de son usage prévu ?** Un score construit pour la priorisation commerciale sera un jour utilisé pour l'évaluation des conseillers.

22.3. L'équité : sortir de la naïveté

Trois faits que le professionnel doit maîtriser pour ne pas dire de bêtises :

- **Les définitions d'équité sont mathématiquement incompatibles entre elles.** On ne peut pas satisfaire simultanément parité démographique, égalité des taux d'erreur et calibration par groupe, sauf cas dégénérés. Choisir une définition est donc un choix politique et métier, pas technique. Le rôle du professionnel est de rendre ce choix explicite et documenté, pas de le faire seul.
- **Retirer la variable sensible ne retire pas le biais.** Les corrélats (code postal, historique, canal de contact) la reconstituent. C'est la première illusion de tous les débutants.
- **Le biais mesuré dans les données peut refléter le monde ou refléter le processus de mesure.** Distinguer les deux change complètement la réponse appropriée.

22.4. La gouvernance minimale d'un système

Chaque système en production dispose d'une fiche d'une page, tenue à jour, contenant : sa finalité, son propriétaire métier, son propriétaire technique, ses données d'entrée et leur provenance, sa population concernée, ses limites connues, sa performance actuelle, sa date de dernière revue, sa date de prochaine revue, et sa procédure d'arrêt.

Cette fiche coûte deux heures à créer et vingt minutes par trimestre à maintenir. Son absence coûte, en moyenne, plusieurs semaines lors du premier audit, du premier incident ou du premier départ.

PARTIE V — LES RÉGIMES DE PRATIQUE

23. Startup, scale-up, grand groupe, indépendant : quatre métiers différents

Le même professionnel n'exerce pas le même métier selon le contexte. Confondre les régimes est la cause principale des échecs de recrutement et de reconversion.

23.1. Startup (moins de 50 personnes)

- **Ce qui est demandé** : amplitude maximale. Une seule personne couvre données, analytique, modèle, déploiement, et souvent le tableau de bord du dirigeant.
- **Le piège** : l'urgence permanente interdit la construction d'actifs. On accumule des solutions jetables jusqu'à ce que plus rien ne tienne.
- **Ce qui fait la différence** : savoir décider ce qu'on ne fait pas, et poser trois ou quatre invariants d'ingénierie non négociables dès le début (versionnement, tests de données, définitions certifiées) qui coûtent peu et sauvent tout.
- **Compétence rare et déterminante** : dire au dirigeant que la question qu'il pose n'est pas la bonne, sans y laisser sa place.

23.2. Scale-up (50-500)

- **Ce qui est demandé** : industrialiser sans figer. C'est le régime le plus exigeant techniquement, parce que le volume de dette accumulée en phase startup arrive à échéance en même temps que la croissance.
- **Le piège** : la sur-plateformisation prématurée, importée par des recrues venant de grands groupes.
- **Ce qui fait la différence** : le sens des proportions — quel outillage à quel moment — et la capacité à créer des standards que les autres adoptent volontairement.

23.3. Grand groupe (1000+)

- **Ce qui est demandé** : naviguer. La difficulté technique est souvent inférieure à celle des deux régimes précédents ; la difficulté organisationnelle est d'un ordre supérieur.
- **Le piège** : la dépréciation par sous-emploi. Un professionnel de haut niveau peut passer deux ans à produire des extractions et des tableaux, et sortir de cette période techniquement affaibli.
- **Ce qui fait la différence** : trouver le sponsor réel (celui dont le budget dépend du résultat), obtenir un accès direct aux données, et livrer un premier résultat en moins de six semaines pour acheter de la crédibilité.
- **Discipline défensive obligatoire** : un régime d'entretien des compétences en parallèle, avec production de preuves. Voir Axiome VII et chapitre 24.

23.4. Indépendant

- **Ce qui est demandé** : être choisi. La compétence technique devient une condition d'entrée, plus un différenciateur. Le différenciateur est la spécialisation nette, la preuve, et la capacité à formuler une promesse vérifiable.
- **Le piège majeur** : le généralisme. « Data scientist freelance » est une offre invendable en 2026, parce qu'elle ne permet ni de fixer un prix ni d'être recommandé. Une offre vendable nomme un secteur, un problème et un résultat.
- **Structure d'offre qui fonctionne** : un diagnostic court et facturé (qui qualifie, produit une preuve et crée l'asymétrie d'information favorable), puis une réalisation, puis un accompagnement récurrent.
- **Ce qui fait la différence** : la spécialisation assumée jusqu'à l'inconfort. Un spécialiste refuse 90 % des demandes, et c'est précisément ce refus qui justifie son prix sur les 10 % restants.
- **La contrainte oubliée** : l'obligation de loyauté et les clauses contractuelles quand on prépare une activité indépendante en étant salarié — autorisation écrite préalable, interdiction d'utiliser données, méthodes et contacts de l'employeur, non-concurrence sectorielle. Ces contraintes se lisent avant, pas après.

23.5. Ce qui est invariant

Quel que soit le régime : la décision d'abord, la mesure du baseline, l'honnêteté sur l'incertitude, le déploiement comme condition de valeur, et la propriété des compétences. Les sept axiomes ne dépendent pas du contexte. C'est ce qui en fait des axiomes.

24. Rythme, artisanat et pratique délibérée

24.1. Contre le mythe de la veille

La veille passive — lire des articles, suivre des fils, regarder des conférences — produit une **illusion de progression**. Elle génère de la reconnaissance (« je connais ce terme ») sans générer de compétence (« je sais le faire »). Un professionnel qui consacre cinq heures par semaine à la veille et zéro à la pratique régresse.

Le ratio défendable est de l'ordre de **un pour quatre** : une heure de lecture pour quatre heures de production. Et toute lecture significative doit se terminer par une implémentation minimale, même jetable. C'est le passage à l'implémentation qui révèle ce qu'on n'avait pas compris.

24.2. Le protocole de pratique délibérée

Quatre conditions, aucune facultative :

1. **Une tâche à la limite de la compétence actuelle**. Pas confortable, pas impossible. Si l'on réussit du premier coup, la tâche était trop facile.
2. **Une rétroaction rapide et objective**. Un test qui échoue, un backtest qui chiffre, une revue par quelqu'un de plus compétent. Sans rétroaction, la répétition consolide les erreurs.
3. **La répétition ciblée du point faible**, pas la répétition de l'ensemble. On ne progresse pas en refaisant ce qu'on sait faire.
4. **Une preuve produite**. Un artefact vérifiable. Sans artefact, la séance n'a pas eu lieu.

24.3. Le régime hebdomadaire type

Un rythme éprouvé pour un professionnel en poste, sur des blocs quotidiens de 60 à 90 minutes :

Jour	Mode	Sortie attendue
Lundi	Cadrage — définir le problème de la semaine, critère de succès	Une spécification d'une page
Mardi	Construction — implémenter le chemin le plus court qui fonctionne	Code qui tourne, même laid
Mercredi	Approfondissement — la difficulté qu'on a contournée lundi	Une compréhension nouvelle, documentée
Jeudi	Mesure et exposition — évaluer, chiffrer, rendre consommable	Un chiffre honnête, une interface minimale
Vendredi	Retour d'expérience — ce qui a marché, ce qui a échoué, ce qu'on garde	Une note de dix lignes, archivée

Le vendredi est le jour le plus souvent sacrifié et le plus rentable. Sans lui, on accumule de l'expérience sans en extraire de compétence.

24.4. La notation anti-complaisance

Un journal de progression n'a de valeur que s'il peut donner de mauvaises notes. Échelle courte, colonne de preuve qui plafonne la note :

- **0** — non fait.
- **1** — fait superficiellement, aucun résultat vérifiable.
- **2** — fait, résultat vérifiable, compréhension partielle.
- **3** — fait, résultat vérifiable, capable de l'expliquer et de le refaire autrement.

Règle de plafond : la note ne peut pas dépasser ce que la preuve démontre. Une preuve vide plafonne à 0, quel que soit le temps passé. Une moyenne durablement supérieure à 2,5 signale un manque d'ambition dans le choix des tâches, pas une excellence.

24.5. L'artisanat comme éthique de travail

Trois principes empruntés à l'artisanat, applicables littéralement :

- **On signe ce qu'on produit.** Le nom de l'auteur figure sur le livrable, avec sa date et sa version. Cela change le niveau de soin.
- **On ne cache pas les défauts, on les documente.** Les limites connues d'un modèle figurent dans le livrable, pas dans la tête de son auteur.
- **On transmet.** Un savoir-faire qui n'est pas transmis meurt avec le poste. Le professionnel de haut niveau écrit, forme, et rend les autres capables de faire sans lui.

25. Les dix-huit anti-patterns

Liste de diagnostic. Cinq occurrences ou plus dans une équipe indiquent un problème structurel, pas individuel.

Sur le cadrage

1. **Le projet orphelin** — pas de décision cible, pas d'utilisateur nommé.
2. **La solution en quête de problème** — on a choisi la technologie avant la question.
3. **Le périmètre élastique** — chaque réunion ajoute une demande, aucune n'en retire.

Sur les données

4. **Le nettoyage sans hypothèse** — on impute, on supprime, on plafonne sans se demander ce que la valeur signifiait.
5. **L'historique inexistant** — on découvre au bout de six semaines que les tables sont écrasées.
6. **La définition flottante** — trois chiffres pour la même grandeur, aucun arbitrage.

Sur la modélisation

7. **La fuite non détectée** — performance de rêve, effondrement en production.
8. **Le concours de Kaggle** — trois mois d'optimisation d'une métrique déconnectée de la décision.
9. **Le modèle sans baseline** — on ne sait pas ce qu'on améliore.
10. **La complexité de prestige** — architecture profonde là où un modèle à trois étages suffisait.
11. **Le SHAP causal** — présentation d'importances de features comme des leviers d'action.

Sur la production

12. **Le notebook déployé** — orchestration d'un notebook comme s'il s'agissait d'un service.
13. **Le modèle zombie** — en production, plus personne ne l'utilise, personne ne l'éteint.
14. **Le monitoring décoratif** — des tableaux de bord que personne ne regarde, aucune alerte actionnable.
15. **Le réentraînement aveugle** — automatique, sans validation de promotion.

Sur l'organisation

16. **L'équipe centrale isolée** — techniquement excellente, sans accès au métier, produit des travaux non adoptés.
17. **Le héros indispensable** — une personne détient tout, rien n'est documenté, le départ est une catastrophe.
18. **La démonstration permanente** — une succession de prototypes impressionnants, aucun système en exploitation. Anti-pattern devenu dominant depuis 2024 avec les systèmes génératifs.

PARTIE VI — L'ÉVALUATION

26. Grille de maturité 0-4 par pilier

Grille d'auto-évaluation et d'évaluation. Elle n'a de valeur que si elle est remplie avec des **preuves** en regard de chaque niveau revendiqué. Une auto-évaluation sans preuve est une déclaration d'intention.

Échelle générale :

- **0 — Absent.** Aucune pratique.
- **1 — Notionnel.** Connaît le vocabulaire, ne sait pas faire seul.
- **2 — Opérationnel.** Sait faire dans un cadre balisé, avec supervision.
- **3 — Autonome.** Sait faire seul, sait choisir la méthode, sait détecter ses propres erreurs.
- **4 — Référent.** Sait faire, sait enseigner, sait juger le travail des autres, sait dire quand la méthode n'est pas applicable.

26.1. Grille détaillée

Pilier	Niveau 2 (opérationnel)	Niveau 3 (autonome)	Niveau 4 (référent)
1. Statistique	Applique correctement tests et validations standard	Choisit la méthode, détecte les violations d'hypothèses, quantifie l'incertitude	Sait quand aucun outil standard ne convient ; conçoit un protocole ad hoc défendable
2. Causalité	Sait mener un A/B test et lire un DiD	Choisit un design d'identification, dessine le DAG, mène les tests de réfutation	Traite les cas d'interférence, d'adoption échelonnée, de non-conformité ; arbitre entre designs imparfaits
3. Séries temporelles	Backtest à origine roulante, modèles classiques et gradient boosting	Modèles globaux, hiérarchie, exogènes calendaires fines, prévision probabiliste	Conçoit le système de prévision complet, y compris la boucle de correction humaine et sa mesure
4. Ingénierie logicielle	Code testé, versionné, conteneurisé	Structure un projet, revoit le code d'autrui, refactorise sans casser	Définit les standards d'une équipe, arbitre la dette technique
5. Data engineering analytique	SQL avancé, transformations testées et documentées	Conçoit une couche analytique complète avec contrats et historisation	Arbitre les définitions métier au niveau de l'entreprise
6. MLOps	Déploie et monitore un modèle	Conçoit la chaîne complète, gère les promotions et les retours arrière	Dimensionne la plateforme à l'échelle réelle, définit la gouvernance

Pilier	Niveau 2 (opérationnel)	Niveau 3 (autonome)	Niveau 4 (réfèrent)
7. LLMOps / agentique	Construit un système fonctionnel avec évaluation basique	Construit un dispositif d'évaluation calibré, optimise coût/latence/qualité	Conçoit des architectures fiables sous non-déterminisme, définit les garde-fous et la sécurité
8. Économie de la décision	Traduit une métrique en effet opérationnel	Construit la matrice de coût, optimise contre elle, chiffre en euros	Dialogue au niveau du comité de direction, arbitre l'allocation du portefeuille de projets
9. Cadrage	Pose les cinq questions	Requalifie une demande, mène un pré-mortem, négocie le périmètre	Transforme une demande floue en programme pluriannuel structuré
10. Communication	Livrable structuré, graphiques honnêtes	Adapte à trois publics, défend un résultat contre-intuitif	Fait changer d'avis une direction avec un argument quantifié

26.2. Les profils cibles

Confirmé (5–8 ans) : niveau 3 sur quatre à cinq piliers, dont au moins un des trois piliers techniques de spécialité ; niveau 2 partout ailleurs ; aucun 0 ou 1 sur les piliers 9 et 10.

Senior / expert (8–15 ans) : niveau 4 sur un ou deux piliers, niveau 3 sur cinq à six, niveau 2 sur le reste. **Le niveau 4 sur le pilier 8 (économie de la décision) est ce qui distingue un expert technique d'un expert tout court.**

Le profil déséquilibré à éviter : niveau 4 sur les piliers 1 à 3, niveau 1 sur les piliers 4 à 6, niveau 1 sur 9 et 10. C'est le profil académique en entreprise : brillant, non employable en production, systématiquement frustré.

Le profil déséquilibré symétrique : niveau 3–4 sur 4 à 7, niveau 1 sur 1 à 3 et 8. C'est le profil de l'ingénieur qui déploie efficacement des modèles dont personne n'a vérifié la validité. Plus dangereux que le précédent, parce que ses erreurs vont en production.

27. Le portfolio de preuves

27.1. Le principe

Une compétence non prouvée n'est pas évaluable, donc non valorisable. Le professionnel de 2026 maintient un portefeuille de preuves, non pas pour chercher un emploi, mais **comme dispositif d'auto-évaluation permanent**.

27.2. Ce qui constitue une preuve

Par ordre décroissant de force :

- 1. Un système en production, avec ses chiffres avant/après,** validés par un tiers métier. Force maximale. « Réduction du WMAPE de 18 % relatif sur 400 références, entraînant une baisse de 0,9 jour de couverture, soit 310 k€ de BFR libéré, mesuré sur douze mois. »
- 2. Un post-mortem d'incident** dont on est l'auteur, avec la mesure préventive mise en place. Preuve de maturité extrêmement discriminante, et presque jamais présentée.
- 3. Un refus documenté** qui a évité un projet. « J'ai démontré que l'historique ne permettait pas de construire un jeu d'entraînement honnête ; le projet a été remplacé par une mise en place d'historisation. »

4. **Un actif réutilisé par d'autres** : package interne, framework d'évaluation, template adopté par plusieurs équipes.
5. **Une analyse qui a changé une décision**, avec la trace du changement.
6. **Une contribution publique** : article technique détaillé, contribution à un projet libre, intervention avec support.
7. **Un projet personnel abouti et déployé**. Force moyenne, mais supérieure à tout diplôme récent.
8. **Une certification**. Force faible, non nulle : prouve la couverture d'un périmètre, pas la capacité de jugement.

27.3. Le format de la preuve

Une page par preuve, structure fixe : contexte en trois lignes, problème, contrainte principale, ce qui a été fait, ce qui a été mesuré, ce qui a raté, ce qu'on ferait autrement.

La section « ce qui a raté » est celle qui convainc. Un portefeuille sans échec documenté est soit incomplet, soit malhonnête, et les deux se remarquent en entretien.

27.4. La règle de la mise à jour

Une preuve par trimestre, minimum. Un professionnel incapable de produire une preuve nouvelle en trois mois est en phase de dépréciation, quelle que soit son activité apparente. C'est un signal d'alarme personnel, à traiter comme tel.

28. Recruter : détecter le vrai en quatre-vingt-dix minutes

Section destinée à ceux qui évaluent, et utile à ceux qui sont évalués : savoir ce qui devrait être testé est un moyen de vérifier la sérieux d'un processus.

28.1. Ce qui ne fonctionne pas

- **Les questions de connaissance.** « Quelle est la différence entre L1 et L2 ? » — répondue par n'importe quel assistant, et par n'importe quel candidat ayant révisé la veille. Valeur discriminante nulle en 2026.
- **Les exercices d'algorithmique généraliste.** Ne prédisent rien sur la capacité à cadrer, modéliser ou déployer.
- **Les études de cas à emporter de plus de quatre heures.** Elles mesurent le temps disponible du candidat, pas sa compétence, et sélectionnent contre les personnes ayant des contraintes personnelles.
- **Le nombre d'années d'expérience.** Dix ans peuvent être une année répétée dix fois.

28.2. Le protocole en quatre séquences

Séquence 1 — Le cadrage (25 minutes). On présente une demande métier réelle, floue, avec un commanditaire joué par l'évaluateur. On mesure : les questions posées, l'ordre dans lequel elles viennent, la capacité à identifier la décision cible et le baseline, la détection des impossibilités. **C'est la séquence la plus discriminante des quatre.**

Séquence 2 — La critique (20 minutes). On présente un travail réalisé, contenant trois défauts implantés : une fuite temporelle, une métrique inadaptée à la décision, une conclusion causale tirée d'un modèle prédictif. On mesure combien il en trouve, dans quel ordre, et s'il sait dire lequel est le plus grave.

Séquence 3 — Le système (25 minutes). Conception au tableau d'un système complet à partir d'une contrainte réaliste (volume, latence, criticité, budget). On mesure : la prise

en compte du mode dégradé, du monitoring, du réentraînement, du coût, de l'extinction. Le candidat qui ne parle que du modèle a répondu à un dixième de la question.

Séquence 4 — Le récit d'échec (20 minutes). « Raconte un projet qui a échoué, ce que tu as compris, ce que tu as changé ensuite. » On mesure : la précision des faits, l'attribution honnête des causes, l'existence d'un apprentissage transféré. Le candidat qui n'a jamais échoué n'a jamais pris de risque, ou ment.

28.3. Les cinq signaux positifs forts

1. Il demande le baseline avant de proposer une méthode.
2. Il dit spontanément « je ne sais pas » au moins une fois, puis explique comment il trouverait.
3. Il pose une question sur ce qui se passe quand le système se trompe.
4. Il chiffre spontanément, même approximativement, en unité métier.
5. Il critique une de ses propres décisions passées sans y être invité.

28.4. Les cinq signaux négatifs forts

1. Il propose une architecture avant d'avoir compris le problème.
2. Il ne mentionne jamais l'incertitude.
3. Il attribue tous les échecs passés à des causes externes.
4. Il confond corrélation et causalité dans un exemple qu'il donne lui-même.
5. Il ne pose aucune question sur les données réellement disponibles.

29. Plan 90 jours / 12 mois

Deux plans opératoires : l'un pour une prise de poste, l'autre pour la construction d'un niveau expert.

29.1. Les 90 premiers jours dans un poste

Semaines 1–3 — Cartographier.

- Rencontrer dix personnes, dont au moins six hors de l'équipe data, notamment les opérationnels qui utilisent (ou subissent) les systèmes existants.
- Établir la liste des décisions récurrentes de l'organisation, avec leur fréquence et leur enjeu approximatif.
- Recenser les systèmes existants et leur usage réel (pas leur usage déclaré).
- Identifier les trois définitions métier les plus contestées.

Semaines 4–6 — Livrer petit.

- Choisir un problème de faible ampleur et forte visibilité, réalisable en trois semaines.
- Le livrer en production, même sous forme minimale. L'objectif n'est pas la valeur du livrable, c'est la crédibilité et la découverte des vrais obstacles.
- Documenter tous les points de friction rencontrés : c'est l'audit technique le plus fiable qu'on puisse produire.

Semaines 7–12 — Poser les invariants.

- Un standard de projet (structure, tests, CI) appliqué à tout ce qui sera fait ensuite.
- Un tableau des définitions certifiées, avec propriétaire.
- Un premier système monitoré correctement, servant de modèle.

- Une note de diagnostic à trois mois, remise au sponsor : ce qui va, ce qui ne va pas, ce qu'on propose sur douze mois, avec chiffrage.

Ce qu'il ne faut pas faire : annoncer une refonte, critiquer publiquement l'existant, proposer une plateforme, lancer un projet de plus de deux mois.

29.2. Les 12 mois pour construire un niveau expert sur un axe

Sur la base d'un bloc quotidien de 90 minutes, soit environ 350 heures utiles.

Mois 1–2 — Le socle théorique dur. Un ouvrage de référence du domaine, travaillé avec exercices implémentés, pas lu. Objectif : maîtriser les hypothèses et les conditions de validité, pas les recettes.

Mois 3–5 — La reproduction. Reproduire trois travaux de référence du domaine sur des données publiques, obtenir les résultats annoncés, puis les casser délibérément pour comprendre ce qui les fait tenir. **La reproduction est la méthode d'apprentissage la plus sous-utilisée et la plus efficace.**

Mois 6–8 — Le système propre. Construire un système complet de bout en bout sur un problème réel ou réaliste : données, pipeline testé, modèle, évaluation honnête, déploiement, monitoring, documentation. Un seul système, achevé, vaut mieux que six prototypes.

Mois 9–10 — L'adversité. Soumettre le travail à une critique compétente : revue par un pair plus expérimenté, publication technique détaillée, présentation à un groupe qui pose des questions difficiles. Corriger.

Mois 11–12 — La transmission. Écrire la synthèse, former quelqu'un, produire un actif réutilisable. On ne maîtrise que ce qu'on peut enseigner sans notes.

Critère de réussite à 12 mois : être capable de tenir une conversation de quarante-cinq minutes avec un expert reconnu du domaine sans être pris en défaut sur les fondements, et disposer d'au moins une preuve de niveau 1 ou 2 (voir chapitre 27).

ÉPILOGUE

Le Data Scientist parfait n'existe pas. Ce qu'il faut viser à la place.

La perfection comme direction, pas comme état

Aucun professionnel n'atteint le niveau 4 sur dix piliers. Ceux qui le prétendent sont soit au niveau 2 partout sans le savoir — l'effet classique de l'incompétence qui ne se voit pas —, soit en train de vendre quelque chose.

Ce que ce manifeste décrit n'est pas un individu. C'est **un gradient**. La question utile n'est pas « suis-je parfait ? » mais « dans quelle direction dois-je bouger, et quelle est la preuve que j'ai bougé ? ».

Les cinq marqueurs du professionnel accompli

Si l'on devait comprimer trente pages en cinq lignes, ce serait celles-ci. Un Data Scientist accompli, en 2026 :

1. **Sait ce qu'il ne sait pas, et le dit avant qu'on le lui demande.** L'honnêteté épistémique est le premier marqueur, parce qu'elle conditionne la validité de tout le reste.
2. **Relie systématiquement son travail à une décision et à un ordre de grandeur en euros.** Sans cette chaîne, il produit de l'activité, pas de la valeur.
3. **Livre des systèmes qui survivent à son absence.** Le test du tiroir. Il construit des actifs, pas des dépendances.
4. **Refuse, avec méthode et avec alternative.** Sa capacité à dire non est ce qui rend son oui crédible.
5. **Entretient ses compétences comme un actif dont il est propriétaire,** indépendamment de ce que son poste lui demande, avec des preuves régulières.

Ce qui ne changera pas

Les outils cités dans ce texte seront obsolètes en 2030. Les modèles auront changé deux ou trois fois. Le titre du métier aura peut-être encore bougé.

Ce qui ne bougera pas : la variabilité d'échantillonnage, l'asymétrie des coûts, l'impossibilité d'inférer une causalité sans hypothèse, le fait qu'un système non utilisé ne produit rien, et le fait qu'une organisation fait confiance à des personnes, pas à des modèles.

Le Data Scientist parfait de 2026 est celui qui a compris que son métier n'est pas de produire des modèles, mais de réduire l'incertitude sur laquelle des humains engagent de l'argent, du temps et du risque — et de le faire d'une manière que d'autres peuvent vérifier, contester et reprendre après lui.

Tout le reste est de l'outillage.

ANNEXES

Annexe A — Table de traduction erreur → euros

Modèle générique à instancier au démarrage de chaque projet. Les colonnes 3 et 4 sont remplies avec le métier, jamais seul.

Domaine	Grandeur statistique	Traduction opérationnelle	Traduction financière (à instancier)
Prévision de demande	−1 pt WMAPE	−0,5 à −0,8 jour de couverture	Coût du capital × valeur de stock
Prévision de demande	−1 pt de sous-prévision	−0,2 à −0,4 pt de rupture	Marge unitaire × volume perdu × taux de report
Prévision (produit périssable)	+1 pt de sur-prévision	+0,3 à +0,5 pt de démarque	Coût de revient × volume détruit
Prévision de charge (service)	−1 pt d’erreur hebdo	−0,5 ETP de sur-staffing ou heures sup.	Coût employeur horaire × heures
Churn / rétention	+1 pt de rappel à précision constante	+N clients retenus	Valeur vie client × taux de succès de l’action
Pricing	+0,05 de précision d’élasticité	Meilleur positionnement sur N références	Volume × Δprix × marge
Fraude	−1 pt de faux positifs	−N blocages injustifiés	Coût de traitement + coût de churn induit
Maintenance prédictive	+1 pt de rappel	−N arrêts non planifiés	Coût horaire d’arrêt × durée moyenne
Support automatisé	+1 pt de résolution automatique	−N tickets humains	Coût complet de traitement d’un ticket

Règle d’usage : ce tableau se remplit au cadrage, pas à la fin. Il sert à décider ce qu’on optimise, pas à justifier après coup.

Annexe B — Checklist de mise en production

À utiliser comme porte de sortie. Une case non cochée est un blocage explicite, pas une réserve.

Données

- ☐ Schéma des entrées validé à l’exécution, échec explicite en cas de non-conformité
- ☐ Test de fraîcheur avec seuil défini
- ☐ Test de volumétrie (plage attendue)
- ☐ Tests métier (invariants, cohérence d’agrégats)
- ☐ Comportement défini en cas de données manquantes ou partielles
- ☐ Aucune fuite temporelle vérifiée par audit explicite des features

Modèle

- ☐ Baseline mesuré et documenté
- ☐ Évaluation temporellement honnête (origine roulante si série)
- ☐ Performance par segment, pas seulement globale
- ☐ Incertitude quantifiée et livrée
- ☐ Calibration vérifiée si sorties probabilistes
- ☐ Limites connues documentées

Système

- ☐ Code versionné, testé, revu par un tiers
- ☐ Environnement reproductible et verrouillé
- ☐ Exécution automatisée, sans étape manuelle
- ☐ Traçabilité prédiction → version de modèle → features
- ☐ Retour arrière possible en moins de 15 minutes
- ☐ Mode dégradé spécifié et testé

Exploitation

- ☐ Propriétaire métier nommé
- ☐ Propriétaire technique nommé
- ☐ Alertes actionnables, destinataire identifié
- ☐ Runbook d'incident écrit
- ☐ Mesure de performance réelle en continu
- ☐ Date de revue planifiée
- ☐ Procédure d'extinction définie

Conformité

- ☐ Finalité documentée
- ☐ Population concernée identifiée
- ☐ Analyse d'impact si décision affectant des personnes
- ☐ Voie de contestation si applicable
- ☐ Journalisation conforme aux exigences applicables

Annexe C — Trente questions de cadrage

Sur la décision

1. Quelle décision précise ce travail modifie-t-il ?
2. Qui la prend, nommément ?
3. À quelle fréquence ?
4. Quel délai maximal entre disponibilité de l'information et décision ?
5. Que fait-on aujourd'hui, sans modèle ?
6. Quelle est la performance mesurée de cette pratique actuelle ?
7. Que se passe-t-il si on ne fait rien pendant six mois ?
8. Qui perd quelque chose si ce projet réussit ?

Sur la valeur

9. Combien vaut une amélioration d'un point ?
10. Quelle est l'erreur la plus coûteuse, et de combien ?
11. Le coût est-il symétrique ? Dans quel rapport ?
12. Quel est le seuil en dessous duquel ce projet ne vaut pas d'être fait ?
13. Quelle serait la valeur d'une information parfaite ?

Sur les données

14. Ces données existent-elles historiquement, ou sont-elles écrasées ?
15. Quelle profondeur d'historique exploitable ?
16. Les définitions sont-elles stables sur la période ?
17. Y a-t-il eu des changements de système, de périmètre, de processus ?
18. Quelles informations seront réellement disponibles au moment de la prédiction ?
19. Quel est le délai d'obtention de la vérité terrain ?
20. Qui est propriétaire de ces données, et a-t-on son accord ?

Sur les contraintes

21. Latence maximale acceptable ?
22. Budget d'infrastructure ?
23. Contraintes d'explicabilité, réglementaires ou contractuelles ?
24. Contraintes de monotonie ou de cohérence imposées par le métier ?
25. Qui doit pouvoir maintenir ce système après moi ?

Sur la sortie

26. Sous quelle forme le résultat sera-t-il consommé ?
27. L'utilisateur pourra-t-il corriger manuellement ? Mesurera-t-on ses corrections ?
28. Comment saura-t-on que le système est utilisé ?
29. Quel est le critère d'arrêt du projet en cas d'échec, et à quelle date ?
30. Qui signe la mise en production ?

Annexe D — Lexique des faux amis

Terme employé	Ce qu'il signifie souvent en réunion	Ce qu'il devrait signifier
« Faire de l'IA »	Utiliser une technologie visible	Modifier une décision avec une méthode adaptée
« Le modèle est précis à 95 % »	Exactitude sur un jeu de test déséquilibré	Rien, en l'absence de baseline et de matrice de coût
« Les données sont propres »	Elles sont chargées sans erreur	Elles ont une définition stable, un grain déclaré, des tests métier qui passent
« Temps réel »	Rapide	Latence contrainte, avec un p99 chiffré
« Le modèle explique le churn »	Il a des features corrélées au churn	Rien de causal, sauf design d'identification
« Feature importance »	Ce qui cause le phénomène	Contribution à la prédiction du modèle, dans ce modèle-ci
« Nous avons un POC »	Ça a marché une fois	Rien tant qu'il n'y a pas d'évaluation représentative
« Agent IA »	Un appel de modèle dans une boucle	Système autonome avec garde-fous, budget, évaluation et escalade
« Data-driven »	On regarde des tableaux de bord	Les décisions changent quand les données contredisent l'intuition
« Le modèle a dérivé »	Les performances ont baissé	Rarement la cause réelle ; regarder d'abord la chaîne d'alimentation

Fin du manifeste.